

Projeto 1: Regressão com MLP e Estudo de Ablação

Disciplina: Introdução às Redes Neurais Artificiais

Autor: Gabriely Di Folco Rocha (RA: 188892)

Repositório: <https://github.com/ghostfoxxgoddess3/ANN>

1. Configuração Experimental e Reprodutibilidade

1.1. Inspeção e Caracterização dos Dados

O conjunto de dados utilizado no projeto, denominado `dataset_p1`, possui 300 observações e duas variáveis numéricas, x e y . A variável x foi utilizada como atributo de entrada da rede, enquanto y corresponde à variável-alvo da tarefa de regressão.

Não foram identificados valores ausentes no conjunto de dados. As duas variáveis apresentam tipo numérico de ponto flutuante (`float64`). A variável x possui 300 valores distintos, distribuídos no intervalo $[0, 10]$, com uma observação para cada valor. Além disso, os valores de x são igualmente espaçados ao longo do intervalo. A variável y apresenta valores entre aproximadamente $-1,49$ e $2,66$.

A Tabela ?? apresenta as principais estatísticas descritivas das duas variáveis.

Table 1: Estatísticas descritivas do conjunto de dados.

Estatística	x	y
Contagem	300	300
Média	5.000000	0.465705
Desvio padrão	2.901229	0.726711
Mínimo	0.000000	-1.488851
1º quartil	2.500000	-0.021091
Mediana	5.000000	0.452895
3º quartil	7.500000	0.988865
Máximo	10.000000	2.655266

A inspeção gráfica indica que a relação entre x e y não é linear, apresentando comportamento oscilatório e dispersão das observações ao longo do domínio de x . Essa característica justifica a utilização de um modelo com capacidade de representar relações não lineares. A Figura ?? apresenta a distribuição das observações.




Figure 1: Distribuição das observações do conjunto de dados.

1.2. Pré-processamento e Partição dos Dados

O `dataset_p1` foi dividido segundo duas estratégias distintas, ambas mantendo a proporção de 10% para treinamento, 10% para validação e 80% para teste. Como o conjunto possui 300 observações, cada estratégia resultou em 30 amostras para treinamento, 30 para validação e 240 para teste.

A primeira estratégia consiste em uma partição aleatória, utilizando uma semente fixa igual a 42 para garantir a reprodutibilidade. A segunda consiste em uma partição sistemática baseada nos índices das observações.

Na partição sistemática, os índices foram classificados de acordo com o resto da divisão por 30. Os índices cujo resto pertence ao conjunto $\{0, 10, 20\}$ foram destinados ao treinamento, enquanto aqueles cujo resto pertence a $\{5, 15, 25\}$ foram destinados à validação. As demais observações foram destinadas ao teste.

Como os valores de x são igualmente espaçados e a classificação é baseada nos índices, essa construção distribui as observações de treinamento e validação ao longo de todo o domínio de x . Assim, a partição sistemática não concentra as amostras de treinamento em uma única região do conjunto de dados.

As duas estratégias foram mantidas ao longo de todo o experimento. Isso permite verificar se os efeitos das modificações introduzidas na MLP dependem da composição dos subconjuntos ou se permanecem semelhantes sob diferentes estratégias de particionamento.

Para o pré-processamento, foi utilizado o método `StandardScaler`. Os parâmetros de transformação foram ajustados exclusivamente sobre os dados de treinamento, evitando a utilização de informações

dos conjuntos de validação e teste nessa etapa. Para uma variável genérica v , a transformação é dada por

$$z = \frac{v - \mu_{\text{train}}}{\sigma_{\text{train}}},$$

onde μ_{train} e σ_{train} representam, respectivamente, a média e o desvio-padrão calculados sobre o conjunto de treinamento.

Os parâmetros obtidos no treinamento foram então utilizados para transformar os conjuntos de validação e teste. O procedimento foi aplicado separadamente à variável de entrada x e à variável resposta y , utilizando-se um escalonador específico para cada variável. Dessa forma, as informações das partições de validação e teste não participam do ajuste dos parâmetros de padronização.

Durante a avaliação final, as previsões foram convertidas novamente para a escala original de y por meio da transformação inversa. Assim, as métricas utilizadas durante o treinamento e a seleção puderam ser calculadas no espaço padronizado, enquanto os resultados finais também puderam ser apresentados na unidade original da variável resposta.

1.3. Definição e Otimização Empírica do Modelo Baseline (Vanilla)

O modelo *baseline* foi definido como uma MLP básica treinada estritamente com **SGD padrão**, sem aceleradores adaptativos como Adam e sem termo de *momentum*. Também não foi utilizada regularização explícita por L1, L2 ou Dropout.

A busca empírica pela configuração do modelo envolveu a variação do número de camadas, do número de neurônios por camada, da taxa de aprendizado inicial (η), da função de ativação e do tamanho do lote (*batch size*). O critério de seleção foi exclusivamente o menor MSE observado no conjunto de validação.

A configuração de referência proposta para a MLP foi:

Entrada $\rightarrow$ Dense(128) $\rightarrow$ ReLU $\rightarrow$ Dense(64) $\rightarrow$ ReLU $\rightarrow$ Saída(1).

Os hiperparâmetros utilizados na busca são apresentados na Tabela ???. A busca foi realizada separadamente para as partições aleatória e sistemática.

Table 2: Espaço de busca e configurações selecionadas para o modelo Baseline (Vanilla).

Hiperparâmetro	Valores explorados	Configuração escolhida
Topologia das camadas	(32), (64), (128), (32, 32), (64, 64) e (128, 64)	(128, 64) para ambas
Função de ativação	ReLU e Tanh	ReLU para ambas
Otimizador	SGD padrão, sem momentum	SGD, momentum = 0
Taxa de aprendizado	0,001 e 0,01	0,01 para ambas
Tamanho do lote	8, 16 e 32	16 (aleatória); 32 (sistemática)
Função de custo	Erro Quadrático Médio (MSE)	MSELoss
Critério de parada	<i>Early Stopping</i> , monitorando o erro de validação	Patience = 20 épocas
Semente aleatória	Semente fixa para reprodutibilidade	Seed = 42

O espaço de busca correspondeu a 72 combinações de hiperparâmetros para cada estratégia de partição. A seleção foi realizada exclusivamente a partir do menor MSE obtido no conjunto de validação, mantendo o conjunto de teste intocado.

Para a partição aleatória, a configuração selecionada foi composta por duas camadas ocultas, com 128 e 64 neurônios, respectivamente, ativação ReLU, taxa de aprendizado 0,01 e tamanho de lote 16. O menor MSE de validação foi 0,818838, obtido na época 564. O treinamento foi encerrado na época 584 após o critério de *Early Stopping*.

Para a partição sistemática, a configuração selecionada também foi composta por duas camadas ocultas, com 128 e 64 neurônios, ativação ReLU e taxa de aprendizado 0,01, mas com tamanho de lote 32. O menor MSE de validação foi 0,770725, obtido na época 998. Nesse caso, o treinamento atingiu o limite máximo de 1000 épocas.

Os resultados resumidos da busca são apresentados na Tabela ??.

Table 3: Melhores resultados obtidos na busca do modelo Baseline (Vanilla).

Partição	Arquitetura	Ativação	Batch	MSE val.	Melhor época
Aleatória	(128, 64)	ReLU	16	0,818838	564
Sistemática	(128, 64)	ReLU	32	0,770725	998

A configuração selecionada em cada partição foi então utilizada no treinamento do modelo baseline, cuja dinâmica de otimização foi analisada por meio das curvas de MSE e MAE.

2. Dinâmica de Treinamento e Convergência

O treinamento dos modelos baseline foi acompanhado por meio do MSE e do MAE, calculados ao final de cada época nos conjuntos de treinamento e validação. As duas estratégias de particionamento foram mantidas na análise.

Além do menor valor do erro de validação, foi registrada a época em que esse valor ocorreu e o número total de épocas executadas. O estado do modelo correspondente ao menor MSE de validação foi preservado para as etapas posteriores.

2.1. Divisão aleatória

Para a divisão aleatória, o modelo selecionado na etapa de busca hiperparamétrica possui arquitetura (128, 64), ativação ReLU, taxa de aprendizado 0,01, *batch size* 16 e SGD sem momentum.

figures/baseline_random_curves.png

Figure 2: Evolução do MSE e do MAE no treinamento e na validação para o modelo baseline com divisão aleatória.


O menor MSE de validação foi 0,818838, obtido na época 564. Com critério de parada antecipada de 20 épocas sem melhoria, o treinamento foi encerrado na época 584.

Ao final do treinamento, o MSE no conjunto de treinamento foi 0,651541, enquanto o MSE de validação foi 0,873208. Os respectivos MAEs foram 0,661778 e 0,794267. Esses valores estão na escala padronizada da variável resposta.

A diferença entre o menor MSE de validação e o valor registrado ao final do treinamento também mostra a utilidade do *Early Stopping*: embora o treinamento tenha continuado após a época 564 para confirmar a ausência de novas melhorias, o modelo selecionado corresponde ao estado de menor erro de validação.

2.2. Divisão sistemática

Para a divisão sistemática, foi utilizada a mesma arquitetura (128,64), com ativação ReLU, taxa de aprendizado 0,01 e SGD sem momentum. O *batch size* selecionado foi 32.



figures/baseline_systematic_curves.png

Figure 3: Evolução do MSE e do MAE no treinamento e na validação para o modelo baseline com divisão sistemática.

Nesse caso, o menor MSE de validação foi 0,770725, obtido na época 998. Como o critério de parada antecipada não foi atingido antes do limite máximo, o treinamento foi executado por 1000 épocas.

Ao final do treinamento, o MSE no conjunto de treinamento foi 0,670215, enquanto o MAE foi 0,648229. O MAE de validação correspondente ao melhor ponto foi 0,734492.

2.3. Comparação da dinâmica de treinamento

Os dois particionamentos apresentaram dinâmicas distintas. Na divisão aleatória, o menor erro de validação ocorreu na época 564, seguido pela interrupção na época 584. Na divisão sistemática, o menor erro de validação ocorreu apenas na época 998, próxima ao limite máximo de treinamento.

Essa diferença mostra que o número de épocas necessário para atingir o melhor ponto depende da composição dos dados utilizados no treinamento e na validação. Também evidencia que velocidade de convergência não deve ser usada como substituta de uma métrica de generalização: um modelo pode atingir um ponto estável rapidamente e ainda apresentar erro de validação elevado.

As curvas de MSE e MAE constituem, portanto, a referência para avaliar as alterações introduzidas nas etapas de ablação.

3. Estudo de Ablação e Desempenho no Conjunto de Teste

Após a definição do modelo baseline, foram avaliadas quatro variações individuais e uma configuração combinada, seguindo o roteiro experimental: inclusão de momentum, regularização L2, regularização L1, Dropout e, por fim, combinação de componentes selecionados a partir dos experimentos individuais.

Em cada ablação, foram preservadas a arquitetura e as condições do baseline correspondente ao particionamento, alterando-se o componente específico sob investigação. Dessa forma, as diferenças observadas podem ser atribuídas ao mecanismo introduzido dentro das condições do experimento.

O conjunto de teste, correspondente a 80% das observações, permaneceu intocado durante todas as etapas de treinamento e seleção.

O principal critério de comparação foi o menor MSE observado no conjunto de validação. A MAE foi utilizada como métrica complementar. Os resultados desta etapa estão no espaço padronizado da variável resposta.

3.1. Baseline + Momentum

A primeira ablação consistiu na inclusão de momentum no otimizador SGD, utilizando $\beta = 0,9$, sem alteração da arquitetura, taxa de aprendizado ou tamanho do lote.


Table 4: Resultados da ablação com momentum.

Split	MSE val.	MAE val.	Melhor época	Épocas
Random	0,701855	0,689057	152	172
Systematic	0,920469	0,769003	7	27

No particionamento aleatório, a introdução do momentum reduziu o MSE de validação de 0,818838 para 0,701855, uma redução de aproximadamente 14,29%. A MAE também diminuiu, de 0,794267 para 0,689057. O menor erro de validação foi atingido na época 152.

No particionamento sistemático, o comportamento foi diferente. O MSE de validação aumentou de 0,770725 para 0,920469, enquanto a MAE passou de 0,734492 para 0,769003. O melhor ponto ocorreu já na época 7.

Portanto, dentro das configurações avaliadas, o efeito do momentum não foi uniforme entre os dois particionamentos. A alteração do mecanismo de atualização modificou tanto o desempenho de validação quanto a dinâmica de convergência.



figures/momentum_random_curves.png

Figure 4: Dinâmica de treinamento do modelo com momentum no particionamento aleatório.

figures/momentum_systematic_curves.png

Figure 5: Dinâmica de treinamento do modelo com momentum no particionamento sistemático.

3.2. Baseline + Regularização L2

A segunda ablação introduziu regularização L2 por meio do parâmetro `weight_decay`, utilizando $\lambda_{L2} = 10^{-4}$ e mantendo o restante da configuração igual ao baseline.


Table 5: Resultados da ablação com regularização L2.

Split	MSE val.	MAE val.	Melhor época	Épocas
Random	0,804006	0,747255	623	643
Systematic	0,770923	0,734615	999	1000

No particionamento aleatório, o L2 reduziu o MSE de validação de 0,818838 para 0,804006, aproximadamente 1,81%. A MAE também foi reduzida de 0,794267 para 0,747255.

No particionamento sistemático, a alteração foi muito pequena: o MSE passou de 0,770725 para 0,770923 e a MAE passou de 0,734492 para 0,734615.

Assim, para o valor de λ_{L2} utilizado, a regularização produziu uma alteração discreta no erro de validação. Como não foi realizada uma busca pelo melhor valor de λ_{L2} , não é possível generalizar esse comportamento para outras intensidades de regularização.



figures/l2_random_curves.png

Figure 6: Dinâmica de treinamento do modelo com regularização L2 no particionamento aleatório.

figures/l2_systematic_curves.png

Figure 7: Dinâmica de treinamento do modelo com regularização L2 no particionamento sistemático.

3.3. Baseline + Regularização L1

A terceira ablação utilizou penalização pela norma L1 dos pesos, com $\lambda_{L1} = 10^{-4}$. A penalização foi aplicada aos pesos das camadas, sem incluir os *biases*.


Table 6: Resultados da ablação com regularização L1.

Split	MSE val.	MAE val.	Melhor época	Épocas
Random	0,805583	0,747984	623	643
Systematic	0,771047	0,734479	1000	1000

No particionamento aleatório, o L1 reduziu o MSE de validação de 0,818838 para 0,805583, aproximadamente 1,62%. A MAE passou de 0,794267 para 0,747984.


No particionamento sistemático, o MSE foi 0,771047, muito próximo ao baseline de 0,770725. A MAE foi 0,734479.

Os resultados mostram que, com $\lambda_{L1} = 10^{-4}$, a penalização produziu alterações pequenas no erro de validação. A comparação com L2 deve ser interpretada dentro desse mesmo valor de regularização, pois os hiperparâmetros não foram submetidos a uma nova busca para cada método.



figures/l1_random_curves.png

Figure 8: Dinâmica de treinamento do modelo com regularização L1 no particionamento aleatório.



figures/l1_systematic_curves.png

Figure 9: Dinâmica de treinamento do modelo com regularização L1 no particionamento sistemático.

3.4. Baseline + Dropout

A quarta ablação consistiu na introdução de camadas Dropout com probabilidade $p = 0,2$ após as camadas ocultas.

Table 7: Resultados da ablação com Dropout.


Split	MSE val.	MAE val.	Melhor época	Épocas
Random	1,020800	0,824734	39	59
Systematic	0,923539	0,769643	28	48

O Dropout produziu aumento do MSE de validação nos dois particionamentos. No split aleatório, o MSE aumentou de 0,818838 para 1,020800, aproximadamente 24,66%. No split sistemático, o aumento foi de 0,770725 para 0,923539, aproximadamente 19,83%.

Os melhores pontos de validação ocorreram nas épocas 39 e 28, respectivamente. Portanto, embora o melhor ponto tenha ocorrido precocemente, o erro associado a esse ponto foi maior que o observado no baseline.

Uma possível interpretação é que, para a quantidade reduzida de amostras de treinamento deste ex-

perimento, o Dropout com $p = 0,2$ tenha introduzido uma regularização excessiva para a configuração utilizada. Essa hipótese é compatível com os resultados observados, mas é específica do valor de p testado e não permite concluir sobre outras taxas de Dropout.



figures/dropout_random_curves.png

Figure 10: Dinâmica de treinamento do modelo com Dropout no particionamento aleatório.



figures/dropout_systematic_curves.png

Figure 11: Dinâmica de treinamento do modelo com Dropout no particionamento sistemático.

3.5. Modelo Combinado

Por fim, foi avaliada a combinação de momentum e regularização L2, utilizando $\beta = 0,9$ e $\lambda_{L2} = 10^{-4}$. A combinação foi introduzida para verificar se os efeitos observados individualmente poderiam ser mantidos ou ampliados quando os dois mecanismos fossem utilizados simultaneamente.

Table 8: Resultados do modelo combinado.

Split	MSE val.	MAE val.	Melhor época	Épocas
Random	0,723593	0,709413	128	148
Systematic	0,920469	0,769004	7	27

No particionamento aleatório, a combinação apresentou MSE de validação 0,723593, inferior ao baseline (0,818838), mas superior ao resultado obtido com momentum isoladamente (0,701855). Dessa forma, dentro desta configuração, a adição do L2 não produziu ganho adicional em relação ao momentum.

No particionamento sistemático, o modelo combinado apresentou MSE de validação 0,920469, coincidindo com o valor observado para o modelo com momentum isoladamente e permanecendo acima

do baseline (0,770725).

Esses resultados mostram que os efeitos dos componentes não foram aditivos de maneira direta. A combinação precisou ser tratada como uma nova configuração experimental, e seu desempenho foi determinado pelo erro de validação efetivamente observado.



Figure 12: Dinâmica de treinamento do modelo combinado no particionamento aleatório.

figures/combined_systematic_curves.png

Figure 13: Dinâmica de treinamento do modelo combinado no particionamento sistemático.

3.6. Comparação Consolidada das Ablações

A Tabela ?? consolida os resultados de validação de todas as configurações avaliadas.

Table 9: Comparação consolidada das configurações avaliadas no conjunto de validação.

Split	Configuração	MSE val.	MAE val.
Random	Baseline	0,818838	0,794267
Random	Momentum	0,701855	0,689057
Random	L2	0,804006	0,747255
Random	L1	0,805583	0,747984
Random	Dropout	1,020800	0,824734
Random	Momentum + L2	0,723593	0,709413
Systematic	Baseline	0,770725	0,734492
Systematic	Momentum	0,920469	0,769003
Systematic	L2	0,770923	0,734615
Systematic	L1	0,771047	0,734479
Systematic	Dropout	0,923539	0,769643
Systematic	Momentum + L2	0,920469	0,769004

A seleção das configurações destinadas à avaliação final foi realizada exclusivamente pelo critério definido de menor MSE de validação. Para o particionamento aleatório, a configuração selecionada foi o modelo baseline com momentum, com MSE de validação 0,701855. Para o particionamento sistemático, a configuração selecionada foi o modelo baseline, com MSE de validação 0,770725.

Essa seleção foi concluída antes da utilização do conjunto de teste, que permaneceu separado das etapas de treinamento e escolha das configurações.

3.7. Avaliação Final no Conjunto de Teste

Após a seleção baseada exclusivamente no conjunto de validação, cada particionamento teve uma configuração definida para a avaliação final. No particionamento aleatório, foi utilizado o modelo baseline com momentum ($\beta = 0,9$), enquanto no particionamento sistemático foi utilizado o modelo baseline.

O conjunto de teste, composto por 240 observações em cada particionamento, não foi utilizado durante o treinamento ou a seleção dos modelos. Os resultados apresentados na Tabela ?? estão na escala original da variável resposta.

Table 10: Desempenho final no conjunto de teste, no espaço original da variável resposta.

Split	Modelo	MSE	RMSE	MAE	R^2
Random	Momentum	0,447147	0,668690	0,556056	0,112666
Systematic	Baseline	0,419493	0,647683	0,525382	0,190934

No particionamento aleatório, o modelo selecionado com momentum apresentou MSE 0,447147, RMSE 0,668690, MAE 0,556056 e $R^2 = 0,112666$.

No particionamento sistemático, o modelo baseline apresentou MSE 0,419493, RMSE 0,647683, MAE 0,525382 e $R^2 = 0,190934$.

As mesmas métricas calculadas no espaço padronizado foram:

Table 11: Desempenho final no conjunto de teste no espaço padronizado.

Split	Modelo	MSE	RMSE	MAE	R^2
Random	Momentum	0,746377	0,863931	0,718410	0,112666
Systematic	Baseline	0,725588	0,851815	0,690969	0,190934

O valor de R^2 não é alterado pela padronização da variável resposta, enquanto MSE, RMSE e MAE dependem da escala utilizada. Por esse motivo, os resultados finais são apresentados prioritariamente na escala original, mantendo-se os valores padronizados para comparação com as métricas utilizadas durante o treinamento.

A comparação entre validação e teste deve ser realizada separadamente em cada particionamento, pois os conjuntos avaliados são distintos. No split aleatório, o MSE passou de 0,701855 na validação para 0,746377 no teste, um aumento de aproximadamente 6,34%. No split sistemático, o MSE passou de 0,770725 na validação para 0,725588 no teste, uma redução de aproximadamente 5,86%.

Essas diferenças não representam uma alteração do modelo entre as duas etapas, mas sim uma diferença entre o desempenho observado em conjuntos distintos. O conjunto de teste foi utilizado apenas após a seleção das configurações, preservando sua função de avaliação final.

3.8. Análise de Paridade e Resíduos

Para complementar as métricas agregadas, foram analisadas as previsões obtidas no conjunto de teste por meio de gráficos de paridade e de resíduos.

Os gráficos de paridade comparam os valores reais e preditos, tendo como referência a reta ideal

$$\hat{y} = y.$$




Figure 14: Gráfico de paridade do modelo selecionado no particionamento aleatório.



Figure 15: Gráfico de paridade do modelo selecionado no particionamento sistemático.

A análise dos resíduos foi realizada a partir de

$$e_i = y_i - \hat{y}_i.$$

As principais estatísticas descritivas dos resíduos no conjunto de teste são apresentadas na Tabela ??.

Table 12: Resumo estatístico dos resíduos no conjunto de teste.

Split	Média	Mediana	DP	Q_1	Q_3	IQR	Mín.	Máx.	Skew.	Curt.
Random	-0,091612	-0,129840	0,662385	-0,578163	0,445578	1,023741	-1,811030	2,277711	0,147780	-0,153236
Systematic	0,069106	-0,004271	0,643986	-0,382244	0,522215	0,904458	-1,780099	1,986360	0,184936	-0,217566

No particionamento aleatório, a média dos resíduos foi $-0,091612$ e a mediana foi $-0,129840$. Como $e = y - \hat{y}$, resíduos negativos correspondem a previsões superiores aos valores observados. A combinação de média e mediana negativas indica uma pequena tendência nessa direção.

No particionamento sistemático, a média foi $0,069106$, enquanto a mediana foi $-0,004271$. A mediana permanece muito próxima de zero, enquanto a média positiva mostra a influência de parte dos resíduos positivos sobre a distribuição.

A dispersão central dos resíduos foi semelhante nos dois particionamentos. O intervalo interquartil foi $1,023741$ no random e $0,904458$ no systematic. Os valores extremos variaram de $-1,811030$ a $2,277711$ no random e de $-1,780099$ a $1,986360$ no systematic.

As medidas de assimetria foram pequenas e positivas: 0,147780 no random e 0,184936 no systematic. Dessa forma, há uma assimetria positiva leve, sem evidência de assimetria acentuada. A curtose em excesso foi $-0,153236$ no random e $-0,217566$ no systematic. Esses valores descrevem a forma da distribuição dos resíduos, mas não constituem, isoladamente, um teste de normalidade.

A relação entre erro médio e erro quadrático pode ser expressa por

$$\text{MSE} = \text{Var}(e) + [\text{E}(e)]^2.$$

Para o particionamento aleatório, o termo associado à média dos resíduos corresponde a aproximadamente 1,88% do MSE. No particionamento sistemático, essa parcela corresponde a aproximadamente 1,14%. Portanto, a maior parte do erro quadrático observado está associada à dispersão dos resíduos, e não ao seu deslocamento médio.

Os resíduos em função de x são apresentados nas Figuras ?? e ??. Essa representação é particularmente relevante neste problema, pois x é a única variável de entrada e a relação observada entre x e y é não linear.




Figure 16: Resíduos em função de x no particionamento aleatório.




figures/residuals_x_systematic.png

Figure 17: Resíduos em função de x no particionamento sistemático.

Finalmente, os histogramas dos resíduos são apresentados nas Figuras ?? e ??. Essas representações complementam as estatísticas descritivas ao permitir a inspeção visual da concentração dos erros e de suas caudas.

figures/residual_hist_random.png

Figure 18: Distribuição dos resíduos no particionamento aleatório.



figures/residual_hist_systematic.png

Figure 19: Distribuição dos resíduos no particionamento sistemático.

4. Discussão e Lições Aprendidas

Os experimentos mostraram que, no regime utilizado, o desempenho da MLP depende não apenas da arquitetura escolhida, mas também da composição das partições e do mecanismo de treinamento empregado.

O `dataset_p1` possui 300 observações, mas somente 30 foram utilizadas para treinamento em cada estratégia. Assim, o modelo foi ajustado com uma quantidade reduzida de exemplos, enquanto 240 observações permaneceram separadas para a avaliação final.

4.1. Efeito do Regime de Baixa Disponibilidade de Dados

A utilização de apenas 10% das observações para treinamento torna a estimativa da relação entre x e y dependente da composição das amostras utilizadas para ajuste e validação. A diferença entre os dois particionamentos evidencia esse efeito.

No particionamento aleatório, o uso de momentum reduziu o MSE de validação em aproximadamente 14,29%, enquanto L1 e L2 produziram reduções menores, de aproximadamente 1,62% e 1,81%. O Dropout com $p = 0,2$, por sua vez, aumentou o MSE em aproximadamente 24,66%.

No particionamento sistemático, o baseline apresentou MSE de validação 0,770725. L1 e L2 per-

maneceram muito próximos desse valor, enquanto momentum e Dropout elevaram o MSE para 0,920469 e 0,923539, respectivamente.

A diferença entre esses comportamentos mostra que os resultados de uma ablação não podem ser dissociados da forma como os dados foram particionados. Em particular, utilizar apenas uma divisão poderia atribuir a uma técnica um efeito que não se reproduz sob uma partição diferente.

4.2. Comportamento do SGD e Efeito do Momentum

O baseline foi treinado com SGD sem momentum. No particionamento aleatório, a introdução de $\beta = 0,9$ reduziu o MSE de validação de 0,818838 para 0,701855 e deslocou a melhor época de 564 para 152.

No particionamento sistemático, o mesmo mecanismo aumentou o MSE de 0,770725 para 0,920469, enquanto o melhor ponto ocorreu na época 7.

Assim, o experimento evidencia que alterar a dinâmica do otimizador pode produzir efeitos dependentes da distribuição das observações entre treinamento e validação. A diferença também reforça que a época de convergência não deve ser interpretada isoladamente: no systematic, o modelo com momentum atingiu rapidamente seu melhor ponto, mas esse ponto apresentou erro de validação superior ao baseline.

4.3. Comparação entre L1 e L2

As regularizações L1 e L2 foram avaliadas com $\lambda = 10^{-4}$. No particionamento aleatório, os MSEs foram 0,805583 para L1 e 0,804006 para L2, ambos abaixo do baseline de 0,818838.

No particionamento sistemático, L1 apresentou MSE 0,771047 e L2 apresentou 0,770923, enquanto o baseline apresentou 0,770725.

Os resultados indicam que, para a intensidade de regularização utilizada, os efeitos de L1 e L2 sobre o MSE de validação foram pequenos. Não foi realizada uma busca pelos valores de λ para essas regularizações. Portanto, a comparação diz respeito às configurações testadas e não à capacidade máxima de cada método sob uma otimização específica de seu hiperparâmetro.

4.4. Efeito do Dropout

O Dropout com $p = 0,2$ aumentou o erro de validação nos dois particionamentos. O MSE passou de 0,818838 para 1,020800 no random e de 0,770725 para 0,923539 no systematic.

Os melhores pontos ocorreram nas épocas 39 e 28, respectivamente. Portanto, nesse experimento, o treinamento atingiu o melhor ponto rapidamente, mas o ponto obtido apresentou erro de validação maior que o baseline.

Uma interpretação possível é que a aleatoriedade introduzida pelo Dropout tenha representado uma regularização excessiva diante das apenas 30 amostras disponíveis para treinamento. Essa interpretação é compatível com os resultados, mas permanece limitada ao valor $p = 0,2$ utilizado.

4.5. Interação entre Momentum e L2

A combinação entre momentum e L2 apresentou MSE de validação 0,723593 no random e 0,920469 no systematic.

No random, a combinação permaneceu melhor que o baseline, mas não superou o momentum isolado. No systematic, o resultado coincidiu com o experimento de momentum e permaneceu acima do baseline.

Portanto, nesta configuração, os efeitos individuais não foram simplesmente aditivos. A regularização L2 não acrescentou uma redução adicional do erro ao momentum e, em nenhum dos dois particionamentos, a configuração combinada superou simultaneamente todas as configurações individuais.

4.6. Generalização para o Conjunto de Teste

A seleção dos modelos foi realizada exclusivamente com base no conjunto de validação. O conjunto de teste permaneceu reservado para a avaliação final, evitando que seu desempenho influenciasse a escolha da configuração.

No particionamento aleatório, o modelo selecionado com momentum apresentou MSE de teste 0,447147, RMSE 0,668690, MAE 0,556056 e $R^2 = 0,112666$.

No particionamento sistemático, o modelo baseline apresentou MSE de teste 0,419493, RMSE 0,647683, MAE 0,525382 e $R^2 = 0,190934$.

No random, o MSE de teste foi aproximadamente 6,34% maior que o MSE de validação. No systematic, o MSE de teste foi aproximadamente 5,86% menor que o MSE de validação.

Essas diferenças não permitem inferir, isoladamente, que um conjunto seja mais difícil que o outro ou que o modelo tenha mudado de comportamento entre as etapas. Elas são resultado da avaliação em amostras distintas e devem ser interpretadas dentro de cada particionamento.

4.7. Análise dos Resíduos

Os resíduos apresentaram dispersão semelhante nos dois modelos selecionados. O desvio-padrão foi 0,662385 no random e 0,643986 no systematic.

No random, a média e a mediana foram negativas, respectivamente $-0,091612$ e $-0,129840$, indicando uma pequena tendência média de superestimação. No systematic, a média foi $0,069106$ e a mediana foi $-0,004271$, o que indica que a posição central da distribuição ficou muito próxima de zero, apesar da influência de resíduos positivos sobre a média.

A skewness positiva e de pequena magnitude nos dois particionamentos é compatível com uma assimetria leve. Os valores extremos também mostram que existem observações com erros significativamente maiores que a magnitude típica dos resíduos. Como o MSE atribui peso quadrático a esses desvios, algumas poucas observações podem contribuir de maneira relevante para o erro agregado.

A decomposição do MSE mostrou ainda que apenas uma pequena parcela do erro quadrático está associada ao deslocamento médio dos resíduos. Portanto, a principal contribuição para o erro observado está associada à variabilidade dos desvios individuais.

A análise conjunta das métricas e dos gráficos de resíduos é, assim, mais informativa que qualquer uma dessas medidas isoladamente.

4.8. Lições Aprendidas

O experimento evidenciou a importância de separar as etapas de otimização, seleção e avaliação final. O conjunto de teste não foi utilizado para selecionar a arquitetura ou os componentes do modelo, sendo reservado para a estimativa final de generalização.

A busca inicial mostrou que a configuração do baseline também depende da estratégia de particionamento, embora ambas tenham selecionado a mesma arquitetura e ativação. Ao longo das ablações, os efeitos das técnicas foram diferentes entre as partições: momentum apresentou redução importante do MSE no random, mas aumento no systematic; L1 e L2 produziram alterações pequenas; e Dropout com $p = 0,2$ aumentou o erro nos dois casos.

A combinação entre momentum e L2 também não apresentou ganho adicional em relação ao momentum isolado no random e não superou o baseline no systematic. Isso mostra que a combinação de mecanismos de otimização e regularização precisa ser verificada experimentalmente, não sendo suficiente supor que seus efeitos serão cumulativos.

Por fim, a análise do conjunto de teste mostrou que a avaliação por MSE, RMSE, MAE e R^2 deve ser complementada pela inspeção das curvas de treinamento, dos gráficos de paridade e dos resíduos. Essa análise conjunta permite distinguir o comportamento de otimização da capacidade de generalização e explicitar as limitações do experimento, sobretudo diante da quantidade reduzida de observações utilizadas para treinamento.