

Projeto 1: Regressão com MLP e Estudo de Ablação

Disciplina: Introdução às Redes Neurais Artificiais

Autor: Gabriely Di Folco Rocha (RA: 188892)

Repositório: <https://github.com/ghostfoxgoddess3/ANN>

1. Configuração Experimental e Reprodutibilidade

1.1. Inspeção e Caracterização dos Dados

O conjunto de dados utilizado no projeto possui 300 observações e duas variáveis numéricas, denominadas x e y . A variável x será utilizada como atributo de entrada do modelo, enquanto y será utilizada como variável-alvo da tarefa de regressão.

Não foram identificados valores ausentes no conjunto de dados. As duas variáveis apresentam tipo numérico de ponto flutuante (`float64`).

A variável x possui 300 valores distintos, distribuídos no intervalo $[0, 10]$. Os valores são igualmente espaçados, com uma observação para cada valor de x . A variável y apresenta valores entre aproximadamente -1.49 e 2.66 .

A Tabela 1 apresenta as principais estatísticas descritivas das variáveis.

Table 1: Estatísticas descritivas do conjunto de dados.

Estatística	x	y
Contagem	300	300
Média	5.000000	0.465705
Desvio padrão	2.901229	0.726711
Mínimo	0.000000	-1.488851
1º quartil	2.500000	-0.021091
Mediana	5.000000	0.452895
3º quartil	7.500000	0.988865
Máximo	10.000000	2.655266

A inspeção gráfica indica uma relação não linear entre x e y , com comportamento oscilatório e dispersão das observações ao longo do domínio de x . A Figura 1 apresenta a distribuição das observações.

1.2. Pré-processamento e Partição dos Dados

O dataset utilizado no projeto, denominado `dataset_p1`, possui 300 observações e duas variáveis numéricas, sendo x a variável de entrada do modelo, enquanto y será utilizada como variável-alvo da tarefa de regressão.

A primeira estratégia consiste em uma partição aleatória, utilizando uma semente fixa igual a 42 para garantir a reprodutibilidade dos experimentos. A segunda consiste em uma partição sistemática baseada nas posições das observações. Nessa estratégia, foram utilizadas sequências de posições da forma

$$r, r + 30, r + 60, \dots, r + 270.$$

Três dessas sequências foram destinadas ao treinamento e três à validação, enquanto as demais observações foram destinadas ao teste. Essa construção mantém os três subconjuntos distribuídos ao longo do intervalo de valores de x .

Para o pré-processamento, foi utilizado o método de padronização `StandardScaler`. Os parâmetros de transformação foram ajustados exclusivamente sobre os dados de treinamento:

$$z = \frac{x - \mu_{\text{train}}}{\sigma_{\text{train}}},$$




Figure 1: Distribuição das observações do conjunto de dados.

onde μ_{train} e σ_{train} representam, respectivamente, a média e o desvio-padrão calculados no conjunto de treinamento. Os mesmos parâmetros foram posteriormente utilizados para transformar os conjuntos de validação e teste, evitando vazamento de informação entre as partições.

O mesmo procedimento foi aplicado à variável de entrada x e à variável resposta y . Durante a avaliação dos modelos, as previsões poderão ser transformadas novamente para a escala original de y por meio da transformação inversa do escalonamento.

1.3. Definição e Otimização Empírica do Modelo Baseline (Vanilla)

O modelo *baseline* será uma rede MLP básica treinada estritamente com **SGD padrão**, sem aceleradores adaptativos como Adam e sem termo de *momentum*. Nesta etapa também não será utilizada regularização explícita por L1, L2 ou Dropout.

A busca empírica pela configuração do modelo envolverá a variação do número de camadas, do número de neurônios por camada, da taxa de aprendizado inicial (η), da função de ativação e do tamanho do lote (*batch size*). A seleção será realizada exclusivamente com base no menor erro de validação.

A configuração de referência proposta para a MLP é:

$$\text{Entrada} \rightarrow \text{Dense}(128) \rightarrow \text{ReLU} \rightarrow \text{Dense}(64) \rightarrow \text{ReLU} \rightarrow \text{Saída}(1).$$

Os hiperparâmetros previstos para a busca são apresentados na Tabela 2. Os valores efetivamente selecionados serão preenchidos após a execução dos experimentos.

Os erros de treinamento e validação dos modelos avaliados durante a busca serão apresentados após a execução dos experimentos.

2. Dinâmica de Treinamento e Convergência

A evolução das curvas de função de perda (MSE) e da métrica auxiliar MAE ao longo das épocas será monitorada para verificar a dinâmica de treinamento do SGD. Posteriormente, as curvas do modelo Baseline serão comparadas às obtidas pelos modelos modificados no estudo de ablação.

A análise da dinâmica de treinamento considerará:

Table 2: Espaço de busca e configuração do modelo Baseline (Vanilla).

Hiperparâmetro	Valores Explorados	Configuração Escolhida
Topologia das camadas	1, 2 e 3 camadas; 32, 64, 128 e 256 neurônios	A definir após a busca
Função de ativação	ReLU, LeakyReLU, Tanh	A definir após a busca
Otimizador	SGD padrão, sem momentum	A definir após a busca
Taxa de aprendizado	A definir experimentalmente	A definir após a busca
Tamanho do lote	16, 32, 64 e 128	A definir após a busca
Função de custo	Erro Quadrático Médio (MSE)	MSELoss
Critério de parada	Early Stopping, monitorando o erro de validação	Patience = 20 épocas
Semente aleatória	Semente fixa para reprodutibilidade	Seed = 42

Figura a ser gerada durante os experimentos.

Figure 2: Curvas de treinamento e validação do modelo Baseline.

- **Estabilidade do SGD:** comportamento das curvas de erro e possíveis oscilações durante o treinamento;
- **Sobreajuste:** comparação entre os erros de treinamento e validação, considerando o baixo número de amostras disponíveis para treinamento;
- **Aceleração com Momentum:** comparação do comportamento e do número de épocas necessárias para convergência entre o SGD Vanilla e a versão com momentum.

3. Estudo de Ablação e Desempenho no Conjunto de Teste

O estudo de ablação será realizado mantendo-se a arquitetura selecionada para o modelo Baseline e modificando-se individualmente componentes específicos do treinamento. Dessa forma, será possível analisar o efeito de cada componente sobre o desempenho do modelo.

Serão avaliadas, inicialmente, as seguintes variações:

1. **Baseline + Momentum:** inclusão de um fator de momentum no otimizador SGD;
2. **Baseline + Regularização L2:** inclusão de penalização quadrática dos pesos, controlada pelo parâmetro λ_{L2} ;
3. **Baseline + Regularização L1:** inclusão de penalização pela norma L_1 , controlada pelo parâmetro λ_{L1} ;
4. **Baseline + Dropout:** desativação aleatória de neurônios nas camadas ocultas;
5. **Modelo combinado:** combinação dos componentes que apresentarem resultados relevantes nos experimentos individuais.

A avaliação final será realizada sobre as 240 observações do conjunto de teste, que não serão utilizadas durante o treinamento ou seleção dos hiperparâmetros.

Os resultados serão apresentados utilizando as métricas MSE, RMSE, MAE e R^2 , além do número de épocas até a convergência.

Table 3: Resultados do estudo de ablação no conjunto de teste.

Modelo / Variação	MSE	RMSE	MAE	R^2	Épocas
Baseline Vanilla	–	–	–	–	–
Baseline + Momentum	–	–	–	–	–
Baseline + L2	–	–	–	–	–
Baseline + L1	–	–	–	–	–
Baseline + Dropout	–	–	–	–	–
Modelo combinado	–	–	–	–	–

Parity plot a ser gerado

Gráfico de resíduos a ser gerado

Figure 3: Valores reais e preditos no conjunto de teste.

Figure 4: Resíduos do modelo no conjunto de teste.

4. Discussão e Lições Aprendidas

A discussão será elaborada a partir dos resultados experimentais obtidos, considerando especialmente o efeito do regime de poucos dados sobre o treinamento e a generalização da MLP.

Serão analisados os seguintes aspectos:

- **Impacto do SGD Vanilla no regime de poucos dados:** relação entre a quantidade reduzida de amostras de treinamento, sobreajuste e desempenho de generalização;
- **Efeito do Momentum:** alterações na velocidade e na estabilidade da convergência em relação ao SGD sem momentum;
- **Regularização L1 e L2:** comparação dos efeitos das duas formas de penalização sobre os pesos e sobre o desempenho de generalização;
- **Dropout:** análise de seu efeito sobre o erro de treinamento e o desempenho no conjunto de teste;
- **Análise de resíduos:** identificação de possíveis padrões, assimetrias ou regiões do domínio nas quais o modelo apresenta maior erro;
- **Limitações experimentais:** influência do reduzido número de amostras de treinamento e das escolhas realizadas durante a busca de hiperparâmetros.

As conclusões serão preenchidas após a realização dos experimentos, evitando inferências sobre o comportamento dos modelos antes da obtenção dos resultados.