

Projeto 1: Regressão com MLP e Estudo de Ablação

Disciplina: Introdução às Redes Neurais Artificiais

Autor: Gabriely Di Folco Rocha (RA: 188892)

Repositório: <https://github.com/ghostfoxxgoddess3/ANN>

1. Configuração Experimental e Reprodutibilidade

1.1. Inspeção e Caracterização dos Dados

O conjunto de dados utilizado no projeto possui 300 observações e duas variáveis numéricas, denominadas x e y . A variável x será utilizada como atributo de entrada do modelo, enquanto y será utilizada como variável-alvo da tarefa de regressão.

Não foram identificados valores ausentes no conjunto de dados. As duas variáveis apresentam tipo numérico de ponto flutuante (`float64`).

A variável x possui 300 valores distintos, distribuídos no intervalo $[0, 10]$. Os valores são igualmente espaçados, com uma observação para cada valor de x . A variável y apresenta valores entre aproximadamente -1.49 e 2.66 .

A Tabela 1 apresenta as principais estatísticas descritivas das variáveis.

Table 1: Estatísticas descritivas do conjunto de dados.

Estatística	x	y
Contagem	300	300
Média	5.000000	0.465705
Desvio padrão	2.901229	0.726711
Mínimo	0.000000	-1.488851
1º quartil	2.500000	-0.021091
Mediana	5.000000	0.452895
3º quartil	7.500000	0.988865
Máximo	10.000000	2.655266

A inspeção gráfica indica uma relação não linear entre x e y , com comportamento oscilatório e dispersão das observações ao longo do domínio de x . A Figura 1 apresenta a distribuição das observações.

1.2. Pré-processamento e Partição dos Dados

O dataset utilizado no projeto, denominado `dataset_p1`, possui 300 observações e duas variáveis numéricas, sendo x a variável de entrada e y a variável resposta. Foram consideradas duas estratégias de partição dos dados, ambas mantendo a proporção de 10% para treinamento, 10% para validação e 80% para teste, correspondendo a 30, 30 e 240 observações, respectivamente.

A primeira estratégia consiste em uma partição aleatória, utilizando uma semente fixa igual a 42 para garantir a reprodutibilidade dos experimentos. A segunda consiste em uma partição sistemática baseada nas posições das observações. Nessa estratégia, foram utilizadas sequências de posições da forma

$$r, r + 30, r + 60, \dots, r + 270.$$

Três dessas sequências foram destinadas ao treinamento e três à validação, enquanto as demais observações foram destinadas ao teste. Essa construção mantém os três subconjuntos distribuídos ao longo do intervalo de valores de x .

Para o pré-processamento, foi utilizado o método de padronização `StandardScaler`. Os parâmetros de transformação foram ajustados exclusivamente sobre os dados de treinamento:




Figure 1: Distribuição das observações do conjunto de dados.

$$z = \frac{x - \mu_{\text{train}}}{\sigma_{\text{train}}},$$

onde μ_{train} e σ_{train} representam, respectivamente, a média e o desvio-padrão calculados no conjunto de treinamento. Os mesmos parâmetros foram posteriormente utilizados para transformar os conjuntos de validação e teste, evitando vazamento de informação entre as partições.

O mesmo procedimento foi aplicado à variável de entrada x e à variável resposta y . Durante a avaliação dos modelos, as previsões poderão ser transformadas novamente para a escala original de y por meio da transformação inversa do escalonamento.

1.3. Definição e Otimização Empírica do Modelo Baseline (Vanilla)

O modelo *baseline* será uma rede MLP básica treinada estritamente com **SGD padrão**, sem aceleradores adaptativos como Adam e sem termo de *momentum*. Nesta etapa também não será utilizada regularização explícita por L1, L2 ou Dropout.

A busca empírica pela configuração do modelo envolverá a variação do número de camadas, do número de neurônios por camada, da taxa de aprendizado inicial (η), da função de ativação e do tamanho do lote (*batch size*). A seleção será realizada exclusivamente com base no menor erro de validação.

A configuração de referência proposta para a MLP é:

$$\text{Entrada} \rightarrow \text{Dense}(128) \rightarrow \text{ReLU} \rightarrow \text{Dense}(64) \rightarrow \text{ReLU} \rightarrow \text{Saída}(1).$$

Os hiperparâmetros utilizados na busca são apresentados na Tabela 2. A busca foi realizada separadamente para as partições aleatória e sistemática.

Foram avaliadas 72 combinações de hiperparâmetros para cada estratégia de partição. A seleção foi realizada exclusivamente pelo menor MSE obtido no conjunto de validação, mantendo o conjunto de teste intocado.

Para a partição aleatória, a configuração selecionada foi composta por duas camadas ocultas, com 128 e 64 neurônios, respectivamente, ativação ReLU, taxa de aprendizado 0,01 e tamanho de lote 16. O

Table 2: Espaço de busca e configurações selecionadas para o modelo Baseline (Vanilla).

Hiperparâmetro	Valores Explorados	Configuração Escolhida
Topologia das camadas	(32), (64), (128), (32, 32), (64, 64) e (128, 64)	(128, 64) para ambas
Função de ativação	ReLU e Tanh	ReLU para ambas
Otimizador	SGD padrão, sem momentum	SGD, momentum = 0
Taxa de aprendizado	0,001 e 0,01	0,01 para ambas
Tamanho do lote	8, 16 e 32	16 (aleatória); 32 (sistemática)
Função de custo	Erro Quadrático Médio (MSE)	MSELoss
Critério de parada	Early Stopping, monitorando o erro de validação	Patience = 20 épocas
Semente aleatória	Semente fixa para reprodutibilidade	Seed = 42

menor MSE de validação foi 0,818838, obtido na época 564. O treinamento foi encerrado na época 584 após o critério de parada antecipada.

Para a partição sistemática, a configuração selecionada também foi composta por duas camadas ocultas, com 128 e 64 neurônios, ativação ReLU e taxa de aprendizado 0,01, mas com tamanho de lote 32. O menor MSE de validação foi 0,770725, obtido na época 998. O treinamento atingiu o limite máximo de 1000 épocas.

Os resultados resumidos da busca são apresentados na Tabela 3.

Table 3: Melhores resultados obtidos na busca do modelo Baseline (Vanilla).

Partição	Arquitetura	Ativação	Batch	MSE val.	Melhor época
Aleatória	(128, 64)	ReLU	16	0,818838	564
Sistemática	(128, 64)	ReLU	32	0,770725	998

Os erros de treinamento e validação ao longo das épocas serão analisados na etapa de dinâmica de treinamento.

2. Dinâmica de Treinamento e Convergência

A evolução das curvas de função de perda (MSE) e da métrica auxiliar MAE ao longo das épocas será monitorada para verificar a dinâmica de treinamento do SGD. Posteriormente, as curvas do modelo Baseline serão comparadas às obtidas pelos modelos modificados no estudo de ablação.

Figura a ser gerada durante os experimentos.

Figure 2: Curvas de treinamento e validação do modelo Baseline.

A análise da dinâmica de treinamento considerará:

- **Estabilidade do SGD:** comportamento das curvas de erro e possíveis oscilações durante o treinamento;
- **Sobreajuste:** comparação entre os erros de treinamento e validação, considerando o baixo número de amostras disponíveis para treinamento;

- **Aceleração com Momentum:** comparação do comportamento e do número de épocas necessárias para convergência entre o SGD Vanilla e a versão com momentum.

3. Estudo de Ablação e Desempenho no Conjunto de Teste

O estudo de ablação será realizado mantendo-se a arquitetura selecionada para o modelo Baseline e modificando-se individualmente componentes específicos do treinamento. Dessa forma, será possível analisar o efeito de cada componente sobre o desempenho do modelo.

Serão avaliadas, inicialmente, as seguintes variações:

1. **Baseline + Momentum:** inclusão de um fator de momentum no otimizador SGD;
2. **Baseline + Regularização L2:** inclusão de penalização quadrática dos pesos, controlada pelo parâmetro λ_{L2} ;
3. **Baseline + Regularização L1:** inclusão de penalização pela norma L_1 , controlada pelo parâmetro λ_{L1} ;
4. **Baseline + Dropout:** desativação aleatória de neurônios nas camadas ocultas;
5. **Modelo combinado:** combinação dos componentes que apresentarem resultados relevantes nos experimentos individuais.

A avaliação final será realizada sobre as 240 observações do conjunto de teste, que não serão utilizadas durante o treinamento ou seleção dos hiperparâmetros.

Os resultados serão apresentados utilizando as métricas MSE, RMSE, MAE e R^2 , além do número de épocas até a convergência.

Table 4: Resultados do estudo de ablação no conjunto de teste.

Modelo / Variação	MSE	RMSE	MAE	R^2	Épocas
Baseline Vanilla	—	—	—	—	—
Baseline + Momentum	—	—	—	—	—
Baseline + L2	—	—	—	—	—
Baseline + L1	—	—	—	—	—
Baseline + Dropout	—	—	—	—	—
Modelo combinado	—	—	—	—	—




Figure 3: Valores reais e preditos no conjunto de teste.

Figure 4: Resíduos do modelo no conjunto de teste.

4. Discussão e Lições Aprendidas

A discussão será elaborada a partir dos resultados experimentais obtidos, considerando especialmente o efeito do regime de poucos dados sobre o treinamento e a generalização da MLP.

Serão analisados os seguintes aspectos:

- **Impacto do SGD Vanilla no regime de poucos dados:** relação entre a quantidade reduzida de amostras de treinamento, sobreajuste e desempenho de generalização;
- **Efeito do Momentum:** alterações na velocidade e na estabilidade da convergência em relação ao SGD sem momentum;
- **Regularização L1 e L2:** comparação dos efeitos das duas formas de penalização sobre os pesos e sobre o desempenho de generalização;
- **Dropout:** análise de seu efeito sobre o erro de treinamento e o desempenho no conjunto de teste;
- **Análise de resíduos:** identificação de possíveis padrões, assimetrias ou regiões do domínio nas quais o modelo apresenta maior erro;
- **Limitações experimentais:** influência do reduzido número de amostras de treinamento e das escolhas realizadas durante a busca de hiperparâmetros.

As conclusões serão preenchidas após a realização dos experimentos, evitando inferências sobre o comportamento dos modelos antes da obtenção dos resultados.