Guia de Apresentação — Projeto 3

VAE para Fashion-MNIST: roteiro, justificativas e banco de perguntas

Autora: Gabriely Di Folco Rocha

Como usar este guia. A apresentação é conduzida *pelo relatório*. Cada seção abaixo corresponde a uma seção do `main.pdf`: traz (i) a mensagem de uma frase que você deve entregar, (ii) o *porquê* de cada escolha (é o que a banca avalia) e (iii) perguntas prováveis com respostas. Não leia o guia: use-o para ensaiar. A meta é demonstrar que você entende *por que* o VAE funciona, não apenas o que você rodou.

1. Mensagem central (abertura, 30 s)

Abra com o fio condutor, não com o dataset. Sugestão de fala: "Treinei dois VAEs para o Fashion-MNIST com espaços latentes de 2 e 8 dimensões. O projeto é, no fundo, sobre um **compromisso entre compressão e fidelidade**: o espaço 2D é interpretável mas reconstrói pior; o 8D reconstrói melhor mas precisa ser projetado para ser visto. Esse trade-off, capturado pela decomposição do ELBO em reconstrução e KL, organiza todos os resultados."

Se você fixar *uma* ideia na cabeça da banca, que seja esta: **o ELBO tem dois termos em tensão** — reconstrução (quer usar o latente ao máximo) e KL (quer colar o latente no *prior*) — e cada decisão do projeto mexe nesse equilíbrio.

2. O que é um VAE e por que não um autoencoder comum

Mensagem: o VAE é um modelo *generativo* probabilístico, não um compressor. Ele aprende uma *distribuição* no espaço latente, o que permite amostrar imagens novas.

- **Autoencoder determinístico (AE):** mapeia $\mathbf{x} \to z \to \hat{\mathbf{x}}$ com z um ponto. O espaço latente fica cheio de "buracos": amostrar um z qualquer tende a gerar lixo. Não é gerador.
- **VAE:** o encoder produz uma *distribuição* $q_\phi(z \mid x) = \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\sigma}^2)$; o termo KL força essas gaussianas a se aproximarem de um *prior* $\mathcal{N}(\mathbf{0}, \mathbf{I})$. Isso "preenche" e regulariza o espaço, de modo que amostrar $z \sim \mathcal{N}(0, I)$ e decodificar gere imagens plausíveis.

Frase de efeito: "O termo KL é o que transforma um autoencoder em um *modelo generativo*: sem ele, o espaço latente não teria estrutura amostrável." Use a Figura da varredura do plano 2D como evidência visual de que o espaço é contínuo.

3. A função de custo (ELBO) — domine isto

Esta é a parte mais provável de ser cobrada. A loss minimizada é o ELBO negativo:

$$\mathcal{L}(\mathbf{x}) = \underbrace{\mathbb{E}_{q_\phi(z|x)}[-\log p_\theta(x \mid z)]}_{\text{reconstrução (BCE)}} + \beta \underbrace{D_{\mathrm{KL}}(q_\phi(z \mid x) \,\|\, p(z))}_{\text{regularização}}.$$

- **Reconstrução** = BCE somada sobre os 784 pixels, média por imagem. Mede o quão bem o decoder reproduz x. É o termo dominante na prática.
- **KL** = forma fechada para gaussianas diagonais: $-\frac{1}{2}\sum_j(1+\log\sigma_j^2-\mu_j^2-\sigma_j^2)$. Penaliza o posterior por se afastar do *prior*; é um "orçamento de informação" do latente.
- $\beta = 1$ = VAE padrão (Kingma & Welling). $\beta > 1$ (β-VAE) força latentes mais desembaraçados ao custo de reconstrução.

Saiba explicar *por que o ELBO é um limite inferior*: $\log p(x) = \text{ELBO} + D_{\text{KL}}(q_\phi(z|x)\|p_\theta(z|x))$. Como a KL é ≥ 0, o ELBO $\leq \log p(x)$. Maximizar o ELBO empurra a evidência para cima *e* aproxima o posterior aproximado do verdadeiro. (Minimizamos o negativo.)

4. O truque de reparametrização — por que é necessário

Mensagem: sem ele, não há gradiente através da amostragem.

Amostrar $z \sim \mathcal{N}(\mu, \sigma^2)$ é uma operação estocástica: não se retropropaga por um "sorteio". A reparametrização escreve $z = \mu + \sigma \odot \epsilon$, com $\epsilon \sim \mathcal{N}(0, I)$ *externo* ao grafo. A aleatoriedade vira uma entrada; μ e σ viram funções determinísticas e diferenciáveis. Assim o gradiente flui para o encoder.

Detalhe de implementação que impressiona: eu parametrizo `logvar`, não σ. Motivo: $\sigma = \exp(0{,}5 \cdot \text{logvar})$ é sempre positivo sem precisar de restrição, e o log melhora a estabilidade numérica.

5. Arquitetura e escolhas de implementação

Mensagem: MLP simples e simétrica, escolhas conservadoras e justificáveis.

- **Encoder/decoder espelhados**, ReLU nas ocultas. Encoder termina em *duas* cabeças lineares (μ e $\log \sigma^2$).
- **Sigmoide na saída** do decoder: pixels normalizados em $[0, 1]$, e a sigmoide combina naturalmente com a BCE.
- **BCE como reconstrução:** trata cada pixel como uma intensidade em $[0, 1]$. Alternativa seria MSE (verossimilhança gaussiana); BCE costuma dar bordas mais nítidas em imagens tipo MNIST.

P: Por que MLP e não CNN? *R:* Escopo do projeto é a análise do espaço latente, não o estado da arte em reconstrução. A MLP é suficiente, mais leve para CPU e mantém o foco no trade-off reconstrução/KL. Uma CNN melhoraria a reconstrução, mas não muda a história central.

6. Metodologia experimental (o que a banca mais respeita)

Mensagem: separação rigorosa de dados e seleção honesta de modelo.

- **Partição:** 54 000 treino / 6 000 validação (semente 42); os 10 000 de teste ficam *intocados* até a avaliação final e as figuras.
- **Seleção de topologia pela loss de validação**, nunca pelo teste. Isso evita escolher arquitetura olhando o conjunto de avaliação.
- **Busca em dois estágios:** candidatos treinados por até 8 épocas em subamostra de 20 000 (barato); o vencedor re-treinado por até 20 épocas no treino completo. *Early stopping* com *patience* 3 (busca) e 6 (final).
- **Espaço de busca:** ocultas (256), (512, 256), (512, 256, 128), para cada dimensão latente (2 e 8). Adam, $\eta = 10^{-3}$, lote 256.

Antecipe a crítica do atalho: "Usei subamostra e poucas épocas *apenas na busca* para caber em CPU; o modelo final foi treinado no conjunto completo. É um compromisso consciente entre custo e rigor, e a seleção continua baseada na validação completa."

7. Leitura dos resultados numéricos

Tenha estes números na ponta da língua (por imagem):

Latente	Topologia	Loss teste	Recon.	KL
2D	$(512, 256, 128)$	258,2	251,5	6,7
8D	$(512, 256)$	240,7	227,9	12,7

- **8D reconstrói melhor** (227,9 vs 251,5): mais dimensões carregam mais informação por imagem.
- **8D tem KL maior** (12,7 vs 6,7): justamente porque usa mais o latente, afasta-se mais do *prior*. **Essa é a frase-chave do trade-off.**
- **Teste ≈ validação** em ambos: sem sobreajuste severo.
- Na busca 2D, a loss caiu monotonicamente com a profundidade; na 8D, a topologia *intermediária* venceu — a mais profunda não ajudou dentro do orçamento de treino.

Se perguntarem "esse 258 é bom?": o valor absoluto do ELBO não tem unidade interpretável isolada; o que importa é a *comparação relativa* entre configurações e a decomposição recon/KL. Não prometa que é o melhor possível.

8. Exploração do espaço latente e as três perguntas

Clusters? Sim, no 2D: *Trouser*, *Bag* e o grupo de calçados formam regiões contíguas e distintas — *de forma não supervisionada*, pois os rótulos não entram no treino (só colorem o gráfico).

Separação de rótulos? Parcial: boa entre grupos visualmente distintos; as peças de tronco (*T-shirt*, *Pullover*, *Coat*, *Shirt*, *Dress*) se sobrepõem por semelhança de forma.

Quanta variância a projeção ilustra? No 2D, 100% (as duas dimensões são mostradas). No 8D, a PCA em 2 componentes cobre só **34,5%** (18,0% + 16,6%) — dois terços da estrutura ficam nas 6 dimensões descartadas.

O argumento mais fino do projeto: a figura 8D parece *mais misturada* que a 2D, mas isso é em boa parte **artefato da projeção**, não ausência de estrutura. Diga explicitamente: "não concluo que o 8D separa pior; concluo que *a projeção* esconde a separação, porque só vejo 34,5% da variância." Isso mostra maturidade analítica.

9. Banco de perguntas da banca (ensaie em voz alta)

P: Por que o KL do 8D é maior que o do 2D? *R:* Mais dimensões latentes codificam mais informação por imagem; o posterior se afasta mais do prior $\mathcal{N}(0, I)$, elevando a KL. É o preço da melhor reconstrução.

P: O que é *posterior collapse*? Você observou? *R:* É quando o KL vai a zero e o latente é ignorado (o decoder gera a média). Aqui não houve: o KL estabiliza em patamar positivo (6,7 e 12,7), indicando que o latente é usado.

P: Por que BCE e não MSE na reconstrução? *R:* Com pixels em $[0, 1]$ e sigmoide na saída, a BCE corresponde a uma verossimilhança de Bernoulli por pixel e tende a produzir bordas mais nítidas. MSE (gaussiana) tenderia a borrar.

P: Por que usar μ (e não amostrar z) ao plotar o espaço latente? *R:* Na visualização quero uma representação determinística e estável de cada imagem; a média do posterior é o ponto mais provável. Amostrar adicionaria ruído sem valor analítico.

P: Por que PCA e não t-SNE/UMAP para projetar o 8D? *R:* PCA é linear e me permite *quantificar* a variância retida (34,5%), que é exatamente a terceira pergunta do enunciado. t-SNE/UMAP dariam clusters mais bonitos, mas sem uma medida honesta de quanto da estrutura estou mostrando, e podem criar agrupamentos artificiais.

P: O que β controla? E se aumentasse? *R:* β pondera o KL. Aumentar (β-VAE) força um latente mais desembaraçado e mais colado ao prior, ao custo de pior reconstrução — deslocaria o trade-off para o lado da compressão.

P: Como você geraria imagens novas? *R:* Amostro $z \sim \mathcal{N}(0, I)$ e aplico o decoder. A varredura do plano 2D é essencialmente isso de forma estruturada, e mostra que o espaço é contínuo e amostrável.

P: Por que a loss de validação, e não a acurácia, guia a seleção? *R:* VAE é não supervisionado; não há rótulo para prever. O critério natural é a própria verossimilhança aproximada (ELBO) no conjunto de validação.

P: A topologia mais profunda nem sempre venceu. Por quê? *R:* No 8D, a $(512, 256, 128)$ perdeu para a $(512, 256)$. Mais capacidade não garante menor loss dentro de um orçamento fixo de épocas/dados; pode treinar mais devagar ou sobreajustar. A seleção por validação captura isso.

P: Qual a maior limitação do trabalho? *R:* Orçamento de treino reduzido (CPU, subamostra na busca) e MLP em vez de CNN. Nada disso compromete a análise do trade-off, mas melhores reconstruções exigiriam convolução e mais épocas.

10. Checklist final (1 min antes de começar)

- Sei desenhar o ELBO e nomear seus dois termos.
- Sei explicar reparametrização em uma frase (gradiente pela amostragem).
- Tenho os 4 números: recon/KL de 2D (251,5 / 6,7) e 8D (227,9 / 12,7).
- Sei dizer por que $\mathrm{KL}_{8D} > \mathrm{KL}_{2D}$ (o trade-off).
- Sei defender PCA pela *variância quantificável* (34,5%).
- Sei admitir limitações (CPU, MLP) sem fragilizar a conclusão.