Projeto 3: Modelo Generativo (VAE) para Fashion-MNIST

Disciplina: Introdução às Redes Neurais Artificiais

Autor: Gabriely Di Folco Rocha

Repositório: https://github.com/ghostfoxgoddes3/ANN

---

1. Objetivo e Escopo

Este projeto treina um modelo generativo do tipo *Variational Autoencoder* (VAE) sobre o conjunto Fashion-MNIST. O objetivo é duplo: (i) ajustar a topologia do modelo de modo a minimizar a função de custo no conjunto de validação, considerando duas configurações de espaço latente, com 2 e 8 dimensões; e (ii) explorar o espaço latente aprendido, verificando a formação de *clusters*, a separação dos rótulos e, no caso 8D, quanto da variância uma projeção bidimensional consegue ilustrar.

O Fashion-MNIST contém imagens em tons de cinza de 28×28 pixels, distribuídas em dez classes de vestuário: *T-shirt/top*, *Trouser*, *Pullover*, *Dress*, *Coat*, *Sandal*, *Shirt*, *Sneaker*, *Bag* e *Ankle boot*. Cada imagem é tratada como um vetor $\mathbf{x} \in [0,1]^{784}$, obtido dividindo-se os valores de pixel por 255.

2. Formulação do VAE

O VAE é um modelo latente que assume um gerador $p_\theta(\mathbf{x} \mid \mathbf{z})$ e um *prior* $p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$. Como a posterior verdadeira é intratável, introduz-se um codificador $q_\phi(\mathbf{z} \mid \mathbf{x})$ e otimiza-se o limite inferior da evidência (ELBO). A função de custo minimizada é o ELBO negativo:

$$\mathcal{L}(\mathbf{x}) = \underbrace{\mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})}[-\log p_\theta(\mathbf{x} \mid \mathbf{z})]}_{\text{reconstrução}} + \beta \underbrace{D_{\mathrm{KL}}(q_\phi(\mathbf{z} \mid \mathbf{x}) \,\|\, p(\mathbf{z}))}_{\text{regularização}}.$$

O termo de reconstrução foi implementado como entropia cruzada binária entre a imagem original e a reconstruída, somada sobre os 784 pixels e promediada por amostra. O termo KL possui forma fechada para posteriors gaussianas diagonais:

$$D_{\mathrm{KL}} = -\tfrac{1}{2} \sum_{j=1}^{d} \left(1 + \log \sigma_j^2 - \mu_j^2 - \sigma_j^2\right),$$

em que d é a dimensão latente. Utilizou-se $\beta = 1$ (VAE padrão). A amostragem de $\mathbf{z}$ emprega o truque de reparametrização, $\mathbf{z} = \boldsymbol{\mu} + \boldsymbol{\sigma} \odot \boldsymbol{\epsilon}$, com $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, o que permite a retropropagação através da operação estocástica.

Tanto o codificador quanto o decodificador são MLPs com ativação ReLU. O codificador termina em duas camadas lineares paralelas, para $\boldsymbol{\mu}$ e $\log \boldsymbol{\sigma}^2$; o decodificador reflete a topologia do codificador e termina em uma sigmoide, de modo que as saídas fiquem em $[0,1]$.

3. Configuração Experimental e Reprodutibilidade

3.1. Partição dos dados

O conjunto de treino original (60 000 imagens) foi dividido em 54 000 para treino e 6 000 para validação, com semente fixa igual a 42. O conjunto de teste oficial, com 10 000 imagens, foi mantido separado e utilizado apenas na avaliação final e nas visualizações do espaço latente. A seleção de topologia baseou-se exclusivamente na loss de validação.

3.2. Busca de topologia

Para cada dimensão latente, foram comparadas três topologias de camadas ocultas: (256), $(512, 256)$ e $(512, 256, 128)$. A mesma topologia é usada no codificador e, de forma espelhada, no decodificador. O otimizador foi o Adam com taxa de aprendizado 10^{-3} e tamanho de lote 256. Para acelerar a busca

em ambiente apenas com CPU, cada candidato foi treinado por até 8 épocas sobre uma subamostra de 20 000 imagens de treino, com parada antecipada (*patience* 3) monitorando a loss de validação. A configuração de menor loss de validação foi então re-treinada por até 20 épocas sobre o conjunto de treino completo (54 000 imagens), com *patience* 6.

Table 1: Espaço de busca e condições comuns a todos os experimentos.

Item	**Valor**
Dimensões latentes	2 e 8
Topologias ocultas	(256), $(512, 256)$, $(512, 256, 128)$
Ativação	ReLU (saída do decodificador: sigmoide)
Otimizador	Adam, $\eta = 10^{-3}$
Tamanho de lote	256
Peso KL	$\beta = 1$
Reconstrução	Entropia cruzada binária (soma por imagem)
Épocas (busca / final)	8 / 20, com parada antecipada
Subamostra na busca	20 000 imagens
Semente	42

4. Resultados da Otimização

4.1. Seleção da topologia

A Tabela 2 resume a busca. Para o espaço latente 2D, a loss de validação diminuiu monotonicamente com a profundidade da rede, e a topologia $(512, 256, 128)$ foi selecionada. Para o espaço 8D, a topologia intermediária $(512, 256)$ apresentou a menor loss de validação, superando tanto a rede rasa quanto a mais profunda dentro do orçamento de treino utilizado.

Table 2: Busca de topologia. Loss de validação (ELBO negativo) por candidato.

Latente	**Topologia**	**Parâmetros**	**Loss val.**
2D	(256)	404 244	277,351
2D	$(512, 256)$	1 068 820	266,938
2D	$(512, 256, 128)$	1 133 844	**264,868**
8D	(256)	408 864	254,109
8D	$(512, 256)$	1 073 440	**248,586**
8D	$(512, 256, 128)$	1 136 160	252,269

4.2. Modelos finais

A Tabela 3 apresenta o desempenho dos modelos re-treinados. Em ambos os espaços, o teste reproduz de perto a validação, sem sinais de sobreajuste severo. O modelo 8D alcança reconstrução nitidamente melhor (227,9 contra 251,5 no teste), ao custo de um termo KL maior (12,7 contra 6,7): dimensões latentes adicionais carregam mais informação sobre cada imagem e, por isso, afastam-se mais do *prior*.

Table 3: Desempenho final dos VAEs selecionados. Valores por imagem.

Latente	**Topologia**	**Loss val.**	**Loss teste**	**Recon. teste**	**KL teste**
2D	$(512, 256, 128)$	255,623	258,167	251,497	6,671
8D	$(512, 256)$	238,254	240,676	227,942	12,734

As curvas de treino (Figuras 1 e 2) decompõem a loss de validação em reconstrução e KL ao longo das épocas. Em ambos os casos, a reconstrução é o componente dominante da loss, e o termo KL estabiliza em um patamar coerente com a dimensão latente.

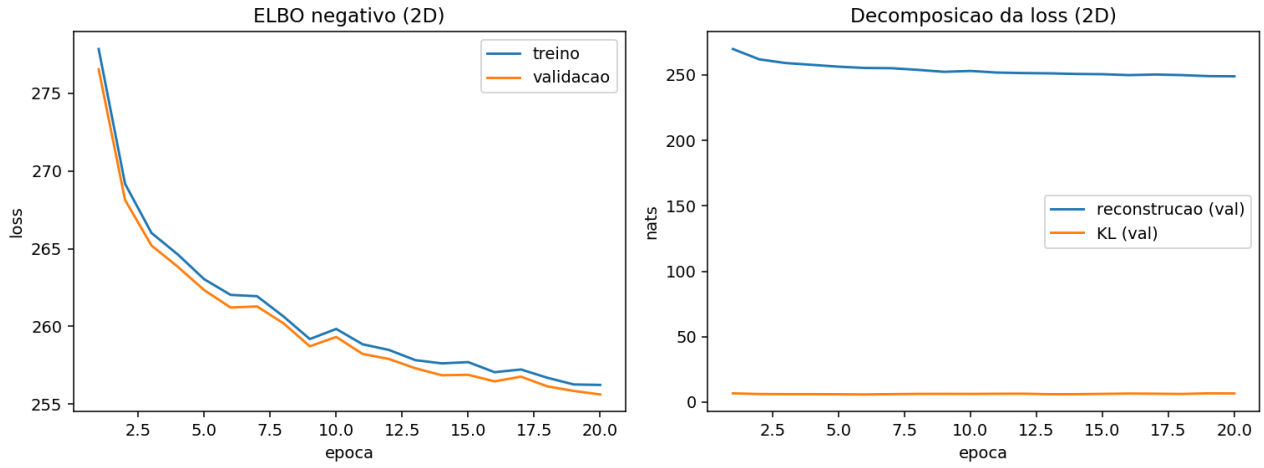


Figure 1: Dinâmica de treino do VAE 2D: ELBO negativo (esquerda) e decomposição da loss de validação em reconstrução e KL (direita).

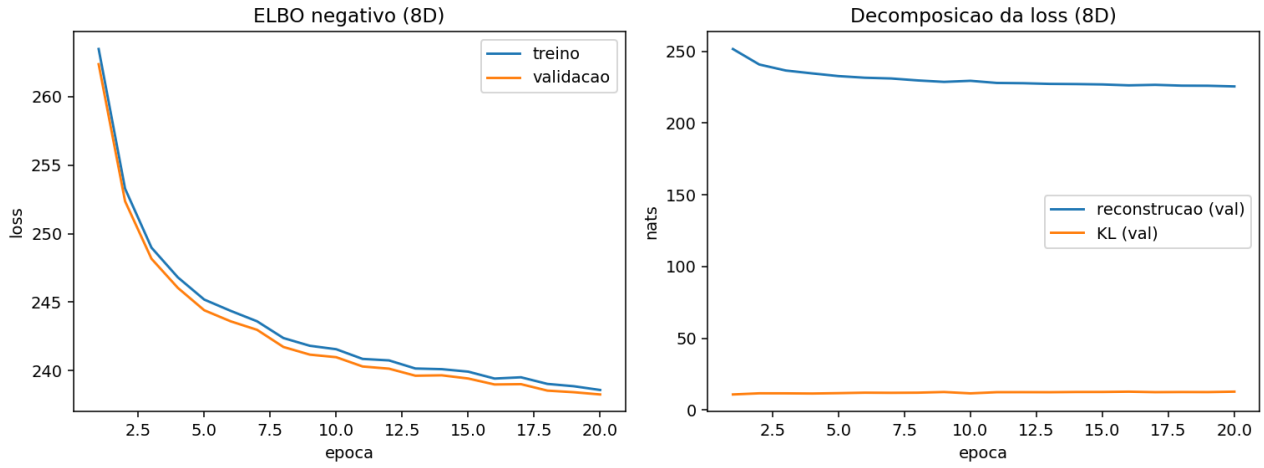


Figure 2: Dinâmica de treino do VAE 8D: ELBO negativo (esquerda) e decomposição da loss de validação em reconstrução e KL (direita).

4.3. Qualidade da reconstrução

As Figuras 3 e 4 comparam imagens originais e suas reconstruções. O VAE 2D captura a silhueta geral das peças, mas perde textura e detalhes finos, efeito esperado de um gargalo de apenas duas dimensões. O VAE 8D produz reconstruções visivelmente mais nítidas, consistentes com o menor erro de reconstrução da Tabela 3.

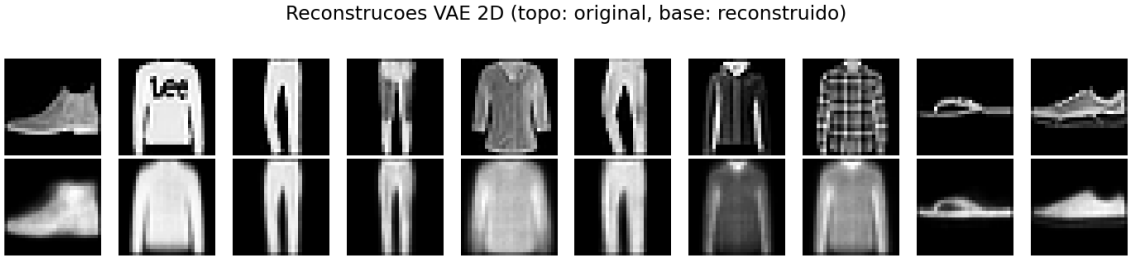


Figure 3: Reconstruções do VAE 2D (linha superior: original; inferior: reconstruída).

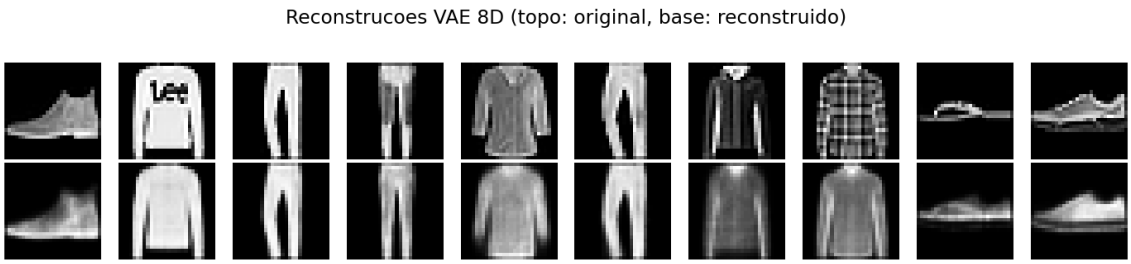


Figure 4: Reconstruções do VAE 8D (linha superior: original; inferior: reconstruída).

5. Exploração do Espaço Latente

Para explorar o espaço latente, codificou-se todo o conjunto de teste (10 000 imagens) usando a média $\boldsymbol{\mu}$ do posterior de cada imagem. No caso 2D, as coordenadas são plotadas diretamente; no caso 8D, aplicou-se PCA e projetaram-se os dois primeiros componentes principais. Os pontos são coloridos pelos rótulos verdadeiros, que não participaram do treino (o VAE é não supervisionado).

5.1. Espaço latente 2D

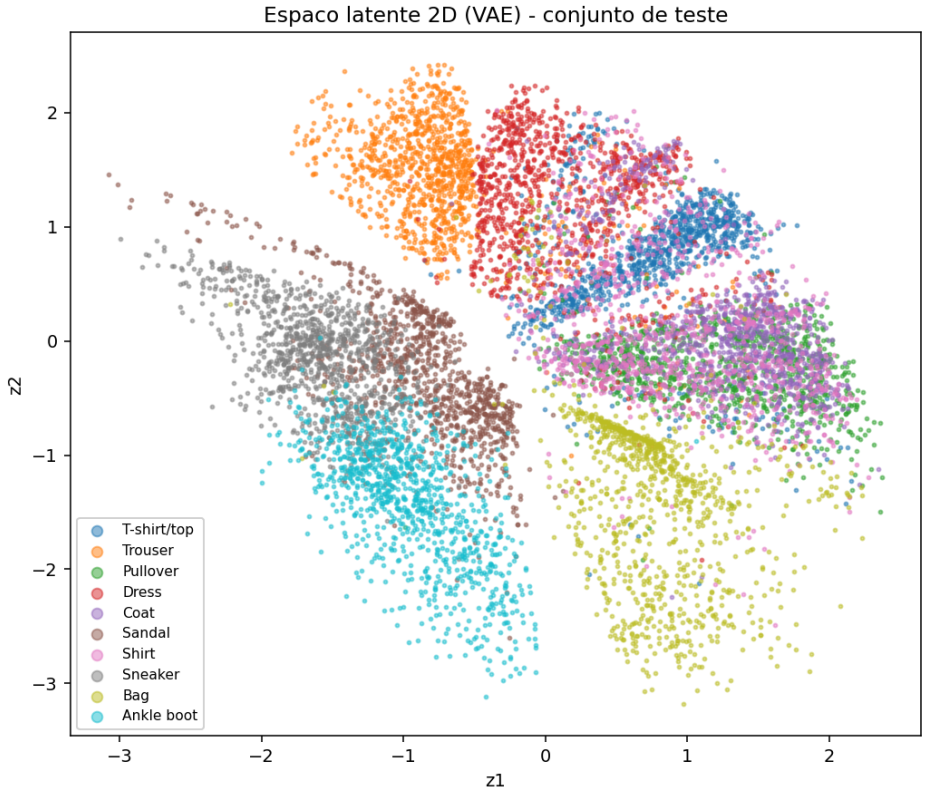


Figure 5: Espaço latente 2D do VAE, colorido pelos rótulos do conjunto de teste.

A Figura 5 mostra organização clara. Os calçados ocupam a metade esquerda e inferior do plano: *Sneaker*, *Sandal* e *Ankle boot* formam regiões contíguas, separadas do restante. A classe *Trouser* ocupa um aglomerado isolado no topo, e *Bag* ocupa a região inferior direita, também bem delimitada. Já as peças de parte superior do corpo — *T-shirt/top*, *Pullover*, *Dress*, *Coat* e *Shirt* — concentram-se à direita e apresentam forte sobreposição entre si, o que é coerente com sua semelhança visual.

A Figura 6 complementa a análise decodificando uma grade regular de pontos do plano latente. A transição suave entre tipos de peça ao percorrer o plano indica que o espaço aprendido é contínuo e organizado por similaridade de forma, propriedade característica de um bom modelo generativo.

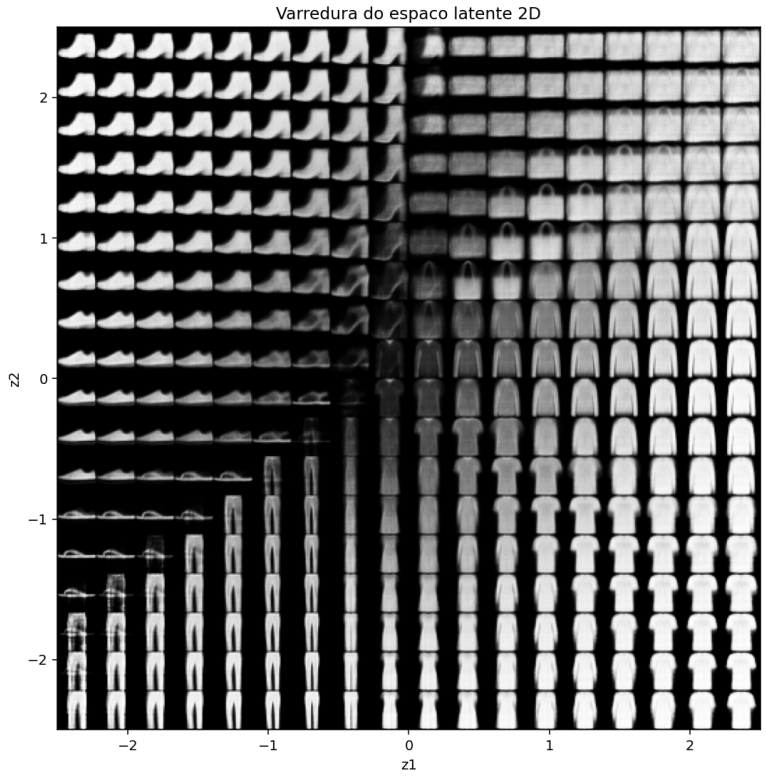


Figure 6: Varredura do plano latente 2D: cada posição é decodificada em uma imagem, revelando a organização contínua do espaço.

5.2. Espaço latente 8D projetado em 2D (PCA)

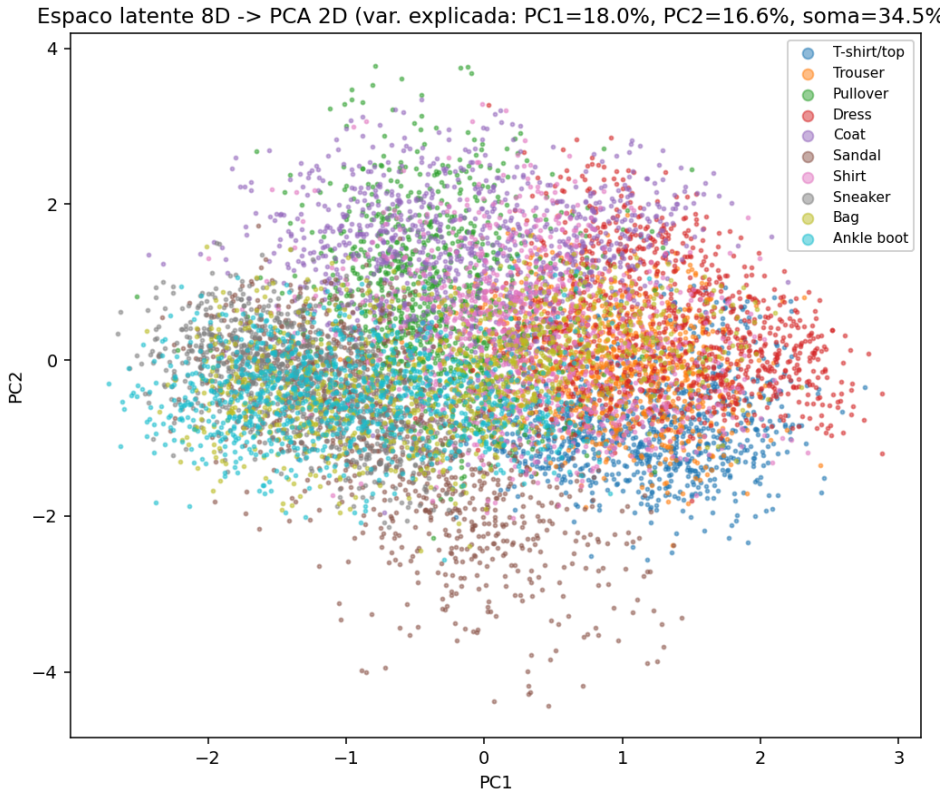


Figure 7: Projeção PCA (2 componentes) do espaço latente 8D, colorida pelos rótulos.

A Figura 7 projeta o espaço 8D nos dois primeiros componentes principais. Observa-se um gradiente por classe — *Dress* e *Trouser* à direita, calçados à esquerda, *Coat* e *Pullover* na parte superior —, mas a separação é visualmente menos nítida que no caso 2D. Esse resultado deve ser interpretado com cautela: a projeção retém apenas parte da informação, como detalhado a seguir.

A Figura 8 mostra a variância explicada por componente. Os dois primeiros componentes respondem por 18,0% e 16,6% da variância, respectivamente, somando apenas **34,5%**. Portanto, cerca de dois terços da variância do espaço 8D residem nas seis dimensões descartadas pela projeção. A aparência mais "misturada" da Figura 7 é, em boa parte, um artefato da projeção, e não necessariamente ausência de estrutura no espaço 8D.

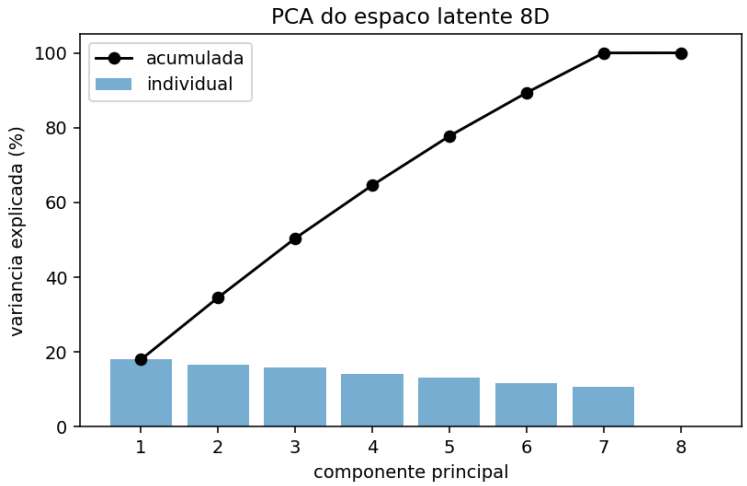


Figure 8: Variância explicada (individual e acumulada) pelos componentes principais do espaço latente 8D.

6. Respostas às Questões Propostas

Há formação de *clusters* no espaço latente? Sim. No espaço 2D, formam-se aglomerados visíveis, com destaque para *Trouser*, *Bag* e o grupo de calçados, que ocupam regiões contíguas e distintas. Os *clusters* emergem de forma não supervisionada, pois os rótulos não foram usados no treino.

Há separação dos rótulos no espaço latente? Parcialmente. A separação é boa entre grupos visualmente distintos (calçados, calças, bolsas), mas as peças de parte superior do corpo (*T-shirt*, *Pullover*, *Coat*, *Dress*, *Shirt*) permanecem sobrepostas, refletindo sua semelhança de forma. O modelo 8D reconstrói melhor, mas sua projeção 2D exibe separação visual menos nítida, principalmente por limitação da própria projeção.

Quanto da variância a projeção ilustra? No caso 2D não há projeção: as duas dimensões são mostradas integralmente. No caso 8D, a projeção PCA em dois componentes ilustra 34,5% da variância total do espaço latente (18,0% no PC1 e 16,6% no PC2). Assim, a visualização 8D representa pouco mais de um terço da estrutura, o que ajuda a explicar por que os rótulos parecem menos separados nessa figura.

7. Conclusões

Foram treinados dois VAEs para o Fashion-MNIST, com espaços latentes de 2 e 8 dimensões, selecionando-se a topologia pela loss de validação. O espaço 2D privilegia a interpretabilidade: produz *clusters* legíveis e um plano latente contínuo, ao custo de reconstruções menos detalhadas. O espaço 8D privilegia a fidelidade: reconstrói melhor as imagens, mas exige projeção para ser visualizado, e dois

componentes principais cobrem apenas 34,5% da sua variância. Em ambos os casos, observou-se organização dos rótulos de forma não supervisionada, com separação clara entre grupos visualmente distintos e sobreposição esperada entre peças de formato semelhante. O compromisso entre compressão e fidelidade — capturado pela decomposição do ELBO em reconstrução e KL — é, portanto, o fio condutor dos resultados.

Referências

1. KINGMA, D. P.; WELLING, M. Auto-Encoding Variational Bayes. In: *International Conference on Learning Representations (ICLR)*, 2014.

2. XIAO, H.; RASUL, K.; VOLLGRAF, R. Fashion-MNIST: a Novel Image Dataset for Benchmarking Machine Learning Algorithms. *arXiv:1708.07747*, 2017.