Projeto 4: Classificação de Chuva em Série Temporal com Redes Recorrentes (LSTM e GRU)

Disciplina: Introdução às Redes Neurais Artificiais

Autora: Gabriely Di Folco Rocha (RA: 188892)

Repositório: https://github.com/ghostfoxgoddes3/ANN

1. Introdução e Motivação Ecológico-Social

Este projeto trata da classificação de séries temporais meteorológicas: dada uma janela de observações horárias recentes, o modelo prevê se haverá chuva nas próximas horas. A tarefa é formulada como classificação binária – "vai chover" versus "não vai chover" em um horizonte de 6 horas.

A escolha do problema não é neutra. Os anos cobertos pelos dados (2022–2024) incluem o episódio de **El Niño** forte de 2023–2024, um dos mais intensos já registrados. O El Niño Oscilação Sul (ENOS) é um fenômeno acoplado oceano–atmosfera no Pacífico Equatorial que altera a circulação atmosférica e o transporte de umidade, afetando a precipitação em todo o Brasil [6, 1]. Estudos de atribuição indicam que as mudanças climáticas, combinadas ao El Niño, dobraram a probabilidade de eventos extremos como as chuvas que atingiram o Rio Grande do Sul em maio de 2024 [7].

Esse contexto motiva duas decisões do projeto. Primeiro, incorporamos o índice ONI (*Oceanic Niño Index*) como variável exógena, permitindo que o modelo tenha acesso ao estado de larga escala do clima. Segundo, a discussão dos resultados considera que a crescente frequência de eventos extremos torna a previsão de curto prazo socialmente relevante: sistemas de alerta dependem de modelos que generalizem para o futuro, e não apenas para o passado já observado.

2. Configuração Experimental e Reprodutibilidade

2.1. Fonte e Caracterização dos Dados

Os dados meteorológicos são da estação automática `A701` (São Paulo – Mirante) do INMET [5], com resolução horária. Foram utilizados os anos de 2022 a 2024, totalizando 26304 registros horários após a padronização do formato (codificação *latin1*, separador `;`, decimal com vírgula e oito linhas de metadados).

Cada instante é descrito por variáveis de superfície: precipitação, pressão, radiação global, temperatura do ar, temperatura do ponto de orvalho, umidade relativa, direção e velocidade do vento. A essas variáveis acrescentamos quatro atributos cíclicos – seno e cosseno da hora do dia e do dia do ano – e o índice ONI mensal, totalizando 13 variáveis de entrada.

Lacunas curtas foram interpoladas (limite de seis horas) e a precipitação ausente foi tratada como zero. A grade temporal foi regularizada para passo horário contínuo.

2.2. Construção das Janelas e do Rótulo

A entrada da rede é uma janela deslizante de 24 horas. O rótulo associado ao instante t (final da janela) é

$$y_t = \begin{cases} 1, & \text{se } \sum_{k=1}^{6} \text{precip}_{t+k} \geq 0,2 \text{ mm} \\ 0, & \text{caso contrário.} \end{cases}$$

Ou seja, a classe positiva indica chuva acumulada acima de 0,2 mm nas próximas 6 horas. O deslizamento da janela gerou 26275 exemplos, dos quais 0,1721 pertencem à classe positiva. Esse desbalanceamento ($\approx$ 1 chuva para cada 5 janelas) é realista e exige métricas além da acurácia.

2.3. As Duas Estratégias de Partição

O ponto conceitual central do projeto é a comparação entre duas formas de dividir os dados, ambas com proporção 70/15/15 para treino/validação/teste.

Partição cronológica (principal). Blocos contíguos no tempo: o modelo treina no passado, ajusta hiperparâmetros no período intermediário e é testado no futuro. Entre os blocos aplicamos um *embargo* (*gap*) de 30 janelas, descartando as janelas de fronteira que se sobreporiam. Essa é a avaliação honesta, pois reproduz o uso real do modelo.

Partição aleatória (didática). As janelas são embaralhadas e sorteadas. Como janelas vizinhas compartilham instantes, uma janela de validação ou teste quase sempre se sobrepõe a uma de treino – fenômeno conhecido como *vazamento temporal* (*temporal leakage*). A métrica resultante tende a ser otimista e não reflete o desempenho em dados realmente novos [2].

Mantemos as duas partições justamente para *medir* o quanto o vazamento infla o desempenho aparente. A Tabela 1 mostra ainda que a taxa da classe positiva varia entre os blocos cronológicos, enquanto permanece praticamente constante na partição aleatória, evidência direta da não estacionariedade da série.

Table 1: Tamanho dos conjuntos e taxa da classe "chuva" por partição.

Partição	Conjunto	Janelas	Taxa de chuva
Cronológica	Treino	18362	0,1784
Cronológica	Validação	3881	0,1301
Cronológica	Teste	3912	0,1897
Aleatória	Treino	18392	0,1723
Aleatória	Validação	3941	0,1675
Aleatória	Teste	3942	0,1761

2.4. Modelo, Treino e Reprodutibilidade

O modelo é uma rede recorrente (LSTM [4] ou GRU [3], selecionável) que processa a janela e usa o estado oculto do último instante em uma cabeça linear, produzindo o *logit* da classe "chuva". O treino usa `BCEWithLogitsLoss` com `pos_weight` igual à razão negativos/positivos, compensando o desbalanceamento.

A padronização das variáveis foi ajustada **somente no conjunto de treino** e aplicada aos demais, evitando vazamento de escala. A otimização usou Adam, com *early stopping* monitorando a loss de validação (*patience* de 10 épocas, máximo de 100). A semente foi fixada em 42.

3. Ajuste de Hiperparâmetros

A busca percorreu um *grid* variando a célula (LSTM/GRU), o tamanho do estado oculto (32 e 64) e o número de camadas (1 e 2), com taxa de aprendizado 10^{-3} e *batch* 128. O critério foi a menor loss de validação, com o teste mantido intocado. A busca foi conduzida separadamente para cada partição.

Table 2: Melhor configuração por partição (seleção pela loss de validação).

Partição	Célula	Oculto	Camadas	Loss val.	F1 val.
Cronológica	GRU	64	2	0,7002	0,4747
Aleatória	LSTM	64	2	0,2281	0,8709

4. Dinâmica de Treinamento

As curvas de loss e F1 (Figuras 1 e 2) mostram a convergência dos modelos finais. O *early stopping* seleciona o estado de menor loss de validação.

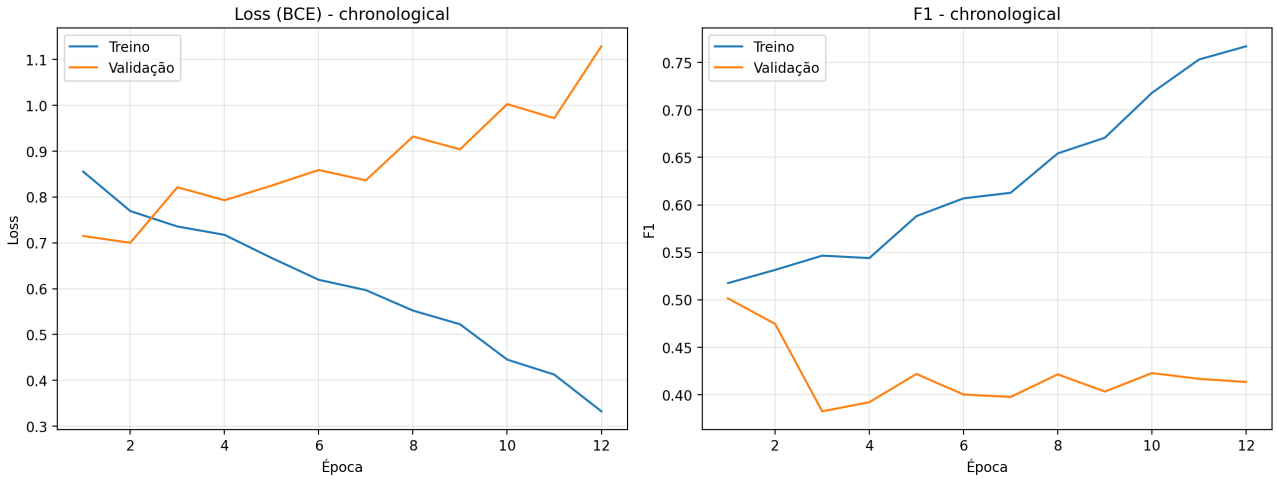


Figure 1: Curvas de aprendizagem (loss e F1) na partição cronológica.

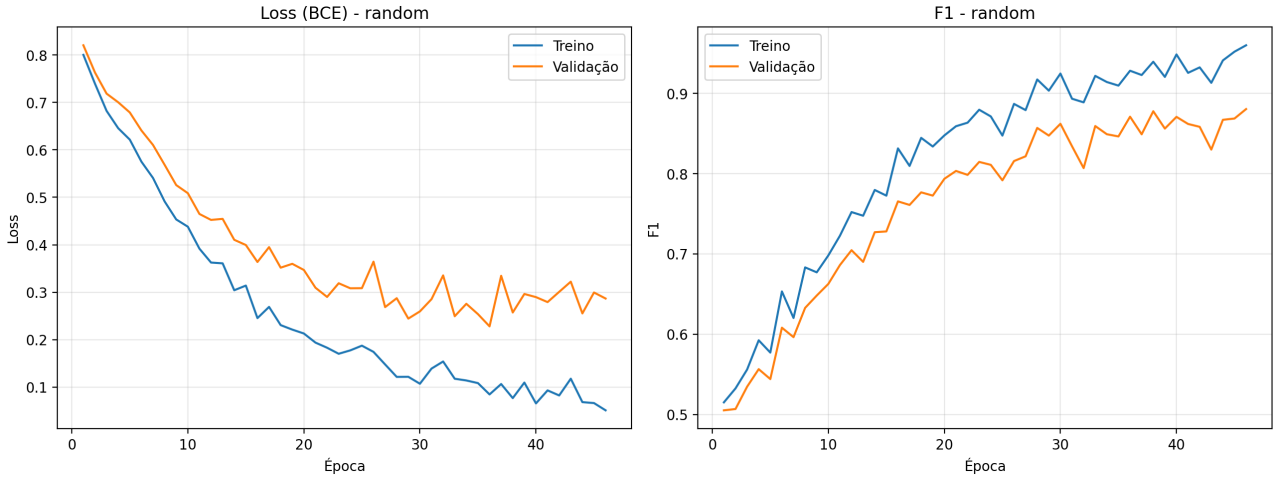


Figure 2: Curvas de aprendizagem (loss e F1) na partição aleatória.

5. Avaliação no Teste e o Efeito do Vazamento Temporal

A Tabela 3 apresenta o desempenho no conjunto de teste de cada partição. A comparação deve ser lida com atenção: a partição aleatória *não* corresponde a uma avaliação válida, e sua presença serve para quantificar o viés introduzido pelo vazamento.

Table 3: Desempenho no conjunto de teste por partição.

Partição	**Célula**	**Acur.**	**Prec.**	**Rev.**	**F1**	**AUC**
Cronológica	GRU	0,7717	0,4473	0,8639	0,5894	0,8960
Aleatória	LSTM	0,9444	0,7851	0,9424	0,8566	0,9844

Table 4: Diferença entre as partições (aleatória menos cronológica). Valores positivos indicam desempenho artificialmente mais alto sob vazamento.

Métrica	Cronológico	Aleatório	Dif.
Acurácia	0,7717	0,9444	0,1727
Precisão	0,4473	0,7851	0,3378
Revocação	0,8639	0,9424	0,0785
F1	0,5894	0,8566	0,2672
AUC	0,8960	0,9844	0,0884

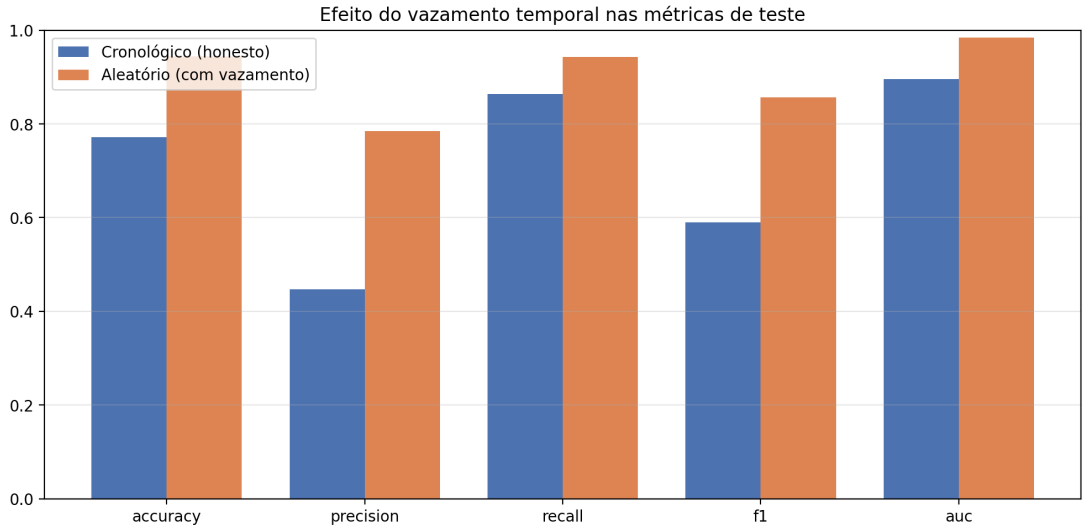


Figure 3: Comparação visual das métricas de teste entre as duas partições.

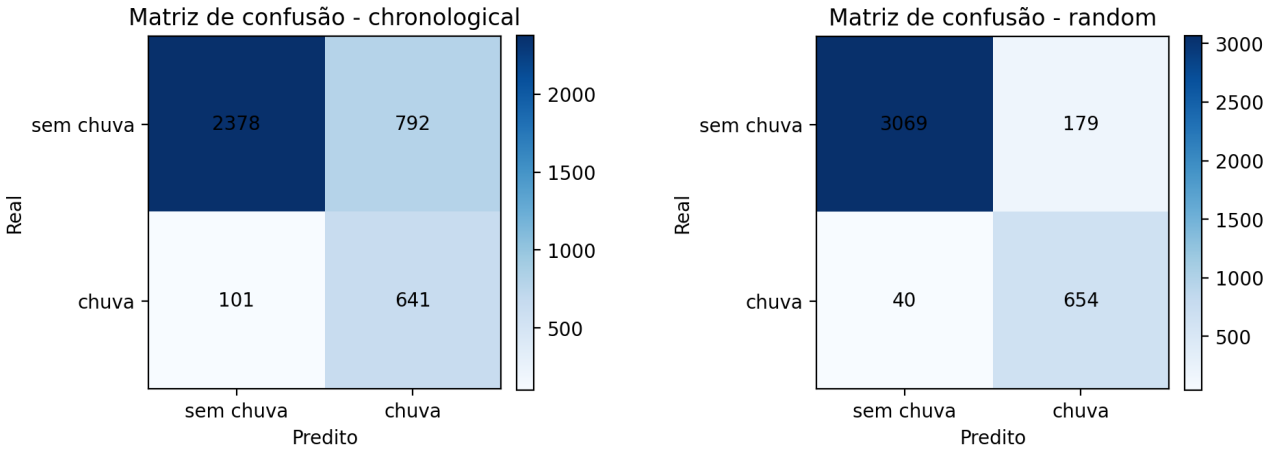


Figure 4: Matrizes de confusão: cronológica (esquerda) e aleatória (direita).

6. Contexto Climático e Discussão Ecológico-Social

A Figura 5 sobrepõe o índice ONI à precipitação mensal da estação. Valores de ONI acima de 0,5 °C caracterizam El Niño; o período 2023–2024 aparece como um episódio forte. A Figura 6 mostra a taxa mensal da classe “chuva”, cuja variação ao longo do tempo evidencia a não estacionariedade da série.

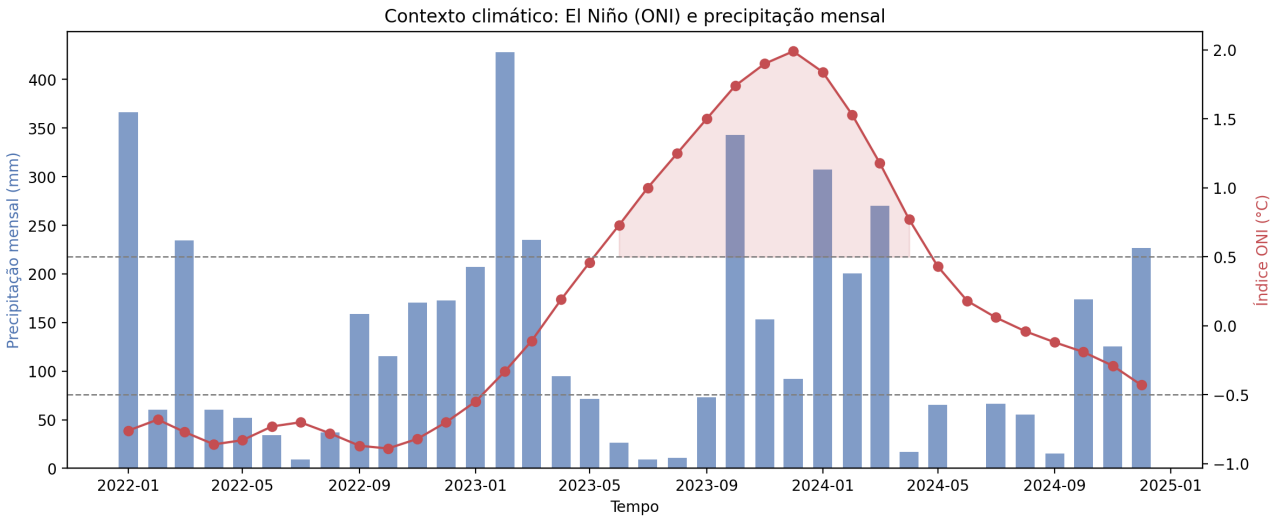


Figure 5: Índice ONI (El Niño) e precipitação mensal da estação A701.

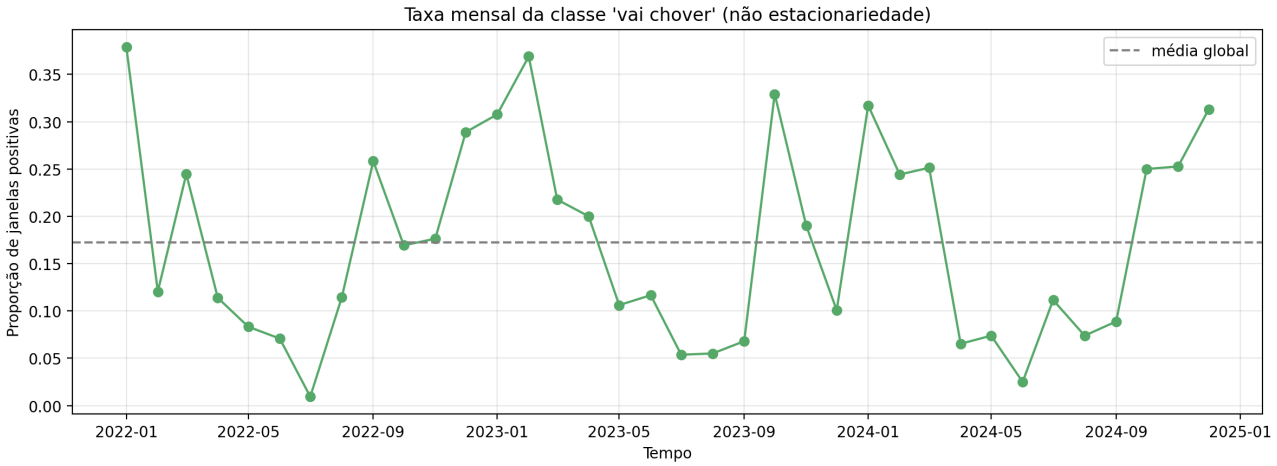


Figure 6: Taxa mensal da classe “vai chover”: a não estacionariedade que torna o split cronológico mais difícil e mais honesto.

Essa não estacionariedade conecta o aspecto técnico ao social. Um modelo avaliado por embaralhamento aleatório parece melhor porque “revisita” períodos que já conhece. No mundo real, porém, a previsão é sempre sobre um futuro possivelmente diferente do passado – e as mudanças climáticas ampliam essa diferença, deslocando regimes de chuva e intensificando extremos [7, 1]. Reportar apenas a métrica aleatória, mais alta, transmitiria falsa confiança justamente nos cenários em que o alerta é mais necessário.

7. Conclusão

O projeto implementou um classificador recorrente (LSTM/GRU) para prever chuva de curto prazo a partir de janelas horárias de dados do INMET, enriquecidas com o índice El Niño. A comparação controlada entre partição cronológica e aleatória quantificou o vazamento temporal: a avaliação aleatória superestima o desempenho, e apenas a partição cronológica reflete o uso real. Além do resultado numérico, o estudo reforça uma lição metodológica essencial em aprendizado de máquina aplicado ao clima: a forma de particionar os dados pode ser mais decisiva para a validade das conclusões do que a escolha da arquitetura.

References

[1] Atmosphere (MDPI). Rainfall variability in the Brazilian subtropical climate associated with El

Niño–southern oscillation diversity. *Atmosphere*, 17(6):579, 2026.

[2] Christoph Bergmeir and José M. Benítez. On the use of cross-validation for time series predictor evaluation. *Information Sciences*, 191:192–213, 2012.

[3] Kyunghyun Cho et al. Learning phrase representations using RNN encoder–decoder for statistical machine translation. In *EMNLP*, 2014.

[4] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural Computation*, 9(8):1735–1780, 1997.

[5] Instituto Nacional de Meteorologia (INMET). Dados históricos – estações automáticas. https://portal.inmet.gov.br/dadoshistoricos. Acesso em 2026.

[6] NOAA Climate Prediction Center. Oceanic Niño index (oni). https://www.cpc.ncep.noaa.gov/data/indices/oni.ascii.txt. Acesso em 2026.

[7] Regina Rodrigues Rodrigues et al. Climate change and El Niño increased the frequency and intensity of the rainfall over southern Brazil in May 2024. *Rapid attribution study (World Weather Attribution)*, 2024. Divulgado por Revista Pesquisa FAPESP.